

Universidad Tecnológica Nacional

Facultad Regional de Rosario

Ingeniería en Sistemas de Información



5° AÑO

Ciencia de Datos

Integrantes:

- Abuin, Leonel
- Anmuth, Matías
- Cabanellas, Miguel
- Montini, Agostino
- Salvia, Ricardo Tomas

Profesores:

- Mg. Ing. Di Carlo, Martina
- Mg. Ing. Scime, Silvia

Índice

Índice	2
1 Fase de entendimiento del negocio	5
1.1 Descripción del problema	5
1.2 Objetivos	6
1.2.1 Objetivos de negocio	6
1.2.2 Objetivos de minería de datos	6
2 Fase entendimiento de los datos	7
2.1 Introducción	7
2.2 Primera limpieza y descripción de los datos	7
2.3 Análisis univariado	9
2.4 Análisis bivariado utilizando la variable objetivo	21
Desarrollo del análisis bivariado de la Etapa 1	22
2.4.1 Variables continuas	22
2.4.1.1 Ocupación de vuelo	22
2.4.1.2 Visibilidad	23
2.4.1.3 Distancia de vuelo	24
2.4.2 Variables categóricas	26
2.4.2.1 Horario de salida	26
2.4.2.1 Día de la semana	30
2.4.2.2 Condiciones climáticas	30
2.4.2.3 Congestión aérea	31
2.4.2.4 Temporada alta	32
2.4.2.5 Tipo de avión	33
2.4.2.6 Puerta de embarque	35
2.4.2.7 Aeropuerto de origen y Aeropuerto de destino	35
2.4.3 Conclusiones del análisis bivariado	38
2.5 Análisis multivariado	40
2.5.1 Ruta aérea	41
2.5.1.1 Desarrollo	41
2.5.1.2 Outliers	43
2.5.2 Congestión aérea y Condiciones climáticas	45
2.5.3 Condiciones climáticas y visibilidad	47
2.5.4 Temporada alta y ocupación de vuelo	49
2.5.5 Otras variables	50
2.5.5.1 Distancia de vuelo y Tiempo estimado de vuelo	50
2.5.5.2 Ruta aérea y otras variables	52
3 Fase de preparación de Datos	54
3.1 Limpieza	54
3.2 Transformación	55
3.2.1 Variables ruta aérea ordenada y ruta aérea única	55
3.2.2 Variable ruta internacional	55
3.3 Vista minable	56

3.4 Configuración de conjuntos de entrenamiento y validación	57
4 Fase de modelado	58
4.1 Definición del proceso de evaluación de modelos	58
4.1.1 Priorización de los falsos negativos	58
4.1.2 Selección de métricas	61
4.2 Evaluación de modelos	62
4.2.1 KNN	62
4.2.1.1 Introducción	62
4.2.1.2 Preparación de Datos	62
4.2.1.3 Desarrollo	63
4.2.2 Árboles de decisión (Modeler)	64
4.2.2.1 Introducción	64
4.2.2.2 Elección del algoritmo	64
4.2.2.3 Preparación de Datos	66
4.2.2.4 Evaluación	66
4.2.3 Árboles de decisión (Python)	69
4.2.3.1 Introducción	69
4.2.3.2 Preparación de Datos	69
4.2.3.3 Evaluación	70
4.2.4 Análisis Discriminante	73
4.2.4.1 Introducción	73
4.2.4.1 Preparación de Datos	73
4.2.4.2 Entrenamiento	74
4.2.4.3 Supuesto de Normalidad	75
4.2.4.4 Supuesto de No multicolinealidad	76
4.2.4.5 Supuesto de matrices de varianza y covarianza iguales	77
4.2.4.7 Evaluación	79
4.2.4.8 Ajuste del modelo seleccionado	82
4.2.4.9 Funcion Discriminante obtenida	84
4.2.5 Regresión Logística	84
4.2.5.1 Preparación de los datos	84
4.2.5.1 Prueba conjunta	84
4.2.5.3 Significancia de coeficientes	85
4.2.5.4 Primer supuesto - Media 0 en el error	89
4.2.5.5 Segundo supuesto - Varianza constante (Homocedasticidad)	90
4.2.5.6 Supuesto 4 - No Multicolinealidad	92
4.2.5.7 Supuesto 5 - Errores no autocorrelados	93
4.2.5.8 Supuesto 6 - Independencia entre variables independientes (VI) y el error	95
4.2.5.9 Balanceo y puntos influyentes	96
4.2.5.10 Evaluación del modelo	96
4.2.5.11 Curva ROC	98
4.3 Selección del mejor modelo	101
5 Fase entendimiento de los datos	103

5.1 Descripción de los datos	103
5.2 Análisis univariado	104
5.3 Análisis bivariado	114
6 Fase de modelado	119
6.1 Clustering Jerárquico	119
6.1.1 Definición del método	119
6.1.2 Conclusión	125
6.2 Cluster Bietápico	125
6.2.1 Desarrollo	125
6.2.2 Conclusión	130
6.3 K - Means	131
6.3.1 Implementación	131
6.3.2 Segmentación K = 2	134
Distribución de clase preferida por cluster	134
Afiliación al programa de millas por cluster	135
Gastos acumulados promedio por cluster	136
Profesiones predominantes por Cluster	136
Canal de compra y sexo por Clusters	137
Validación estadística de clusters mediante diagramas de caja (Boxplots)	138
Distribución de Edad	138
Cantidad de vuelos	139
Gasto acumulado	139
Gastos acumulados extra	140
Cantidad de Millas	141
Ingreso mensual	141
Anticipación de compra promedio	142
6.3.3 Segmentación K = 3	142
6.3.4 Comparativa de modelos y selección del K óptimo	143
6.4 Análisis de componentes principales	145
7 Análisis de los resultados del modelo predictivo y descriptivo	149
Bibliografía	151
Anexo	152
Tablas del análisis bivariado	152

1 Fase de entendimiento del negocio

1.1 Descripción del problema

El problema consiste en minimizar el gasto total de la aerolínea, lo cual puede dividirse en dos subproblemas: determinar anticipadamente qué vuelos sufrirán demoras y definir la compensación más adecuada para cada pasajero afectado.

El gasto a minimizar está compuesto por el costo total asociado a la deserción de clientes y el costo de las compensaciones ofrecidas. Para minimizar el gasto total, se debe encontrar un punto de equilibrio óptimo entre el costo derivado de la deserción de clientes y el gasto asociado a las compensaciones por demoras en los vuelos.

La probabilidad de deserción de un cliente está influenciada por distintos factores, entre ellos, si fue notificado con anticipación acerca de la demora y el tipo de compensación que recibe. A su vez, el impacto económico de dicha deserción depende del valor del cliente, el cual puede estimarse considerando variables como su gasto acumulado en pasajes, sus gastos extra y su ingreso mensual.

Por otro lado, el costo de las compensaciones varía según el beneficio otorgado. En este caso, se contemplan dos alternativas: vouchers para consumo en restaurantes o el acceso a salas VIP en el aeropuerto, siendo esta última la de mayor costo.

En este contexto, resulta necesario aplicar diversas técnicas de minería de datos que permitan analizar el valor de los clientes y predecir la ocurrencia de demoras en los vuelos de forma tal de optimizar la toma de decisiones con el objetivo de minimizar el costo total para la empresa.

1.2 Objetivos

1.2.1 Objetivos de negocio

DS Airlines busca desarrollar un agente inteligente de atención al pasajero que gestione de forma proactiva las situaciones de demora. Los objetivos comerciales son dos:

1. Anticipar demoras y notificar a los pasajeros afectados, reduciendo la probabilidad de deserción y evitando que los clientes migren a la competencia.
2. Minimizar el costo de compensaciones innecesarias, evitando ofrecer beneficios ante vuelos que en realidad no incurrirán en demoras. Como así también evitando otorgar un beneficio costoso, como el pase VIP, a un cliente que no tiene tanto valor potencial para el negocio.

1.2.2 Objetivos de minería de datos

Los objetivos de negocio identificados se corresponden con los siguientes objetivos de minería de datos:

1. Desarrollar un modelo de clasificación binaria que prediga si un vuelo incurrirá en demora o no, utilizando los datos históricos suministrados.
2. Priorizar la detección de vuelos que efectivamente presentarán demoras, minimizando la cantidad de falsos negativos debido al elevado costo asociado a predecir una no demora cuando el vuelo está demorado. Asimismo, mantener una tasa de verdaderos negativos (TNR) de al menos 60%¹, con el fin de evitar que se pierda credibilidad en el modelo y un incremento excesivo de compensaciones innecesarias.
3. Segmentar a los clientes en grupos homogéneos según su valor para la empresa, considerando variables como gasto acumulado en pasajes, gastos extra e ingreso mensual, mediante técnicas de clustering, con el fin de asignar el tipo de compensación más adecuado (voucher o pase VIP) a cada perfil.
4. Facilitar la visualización e interpretación de los segmentos obtenidos mediante técnicas de reducción de dimensionalidad (ACP).

¹ El umbral de TNR establecido, así como la consideración de los falsos negativos como el tipo de error más costoso para el negocio, se justifican en las secciones 4.1.1 y 4.1.2.

2 Fase entendimiento de los datos

2.1 Introducción

Durante el desarrollo de esta sección se llevará a cabo la descripción, análisis exploratorio y evaluación de calidad de los datos brindados por la empresa DS Airlines sobre su registro histórico de vuelos. Entonces, se tendrá por entrada el archivo “vuelos.xlsx” cómo fue recibido y, luego de todo el proceso ya mencionado, se finalizará con un dataset ya claramente comprendido, listo para que se le realicen las modificaciones necesarias que puedan haber surgido de este análisis, previo a ser entregado a los diferentes modelos predictivos desarrollados posteriormente.

2.2 Primera limpieza y descripción de los datos

Como paso inicial en el proceso de análisis, se realizó una primera limpieza del dataset original (vuelos.xlsx) con el objetivo de reducir el número de variables que, de forma evidente, no aportan nada a la predicción del modelo, añadiendo ruido al mismo.

En principio, la columna eliminada es la de **id_vuelo**, dado que es una variable identificadora que actúa como clave primaria o foránea en el sistema original, ya que no aporta información sobre una posible demora. Además, al ser únicas para cada fila, podrían inducir a los algoritmos de aprendizaje automático a encontrar patrones artificiales que no generalizan.

Otro detalle es que convertimos la variable de **puerta_embarque** de numérica a categórica, dado que no tiene mucho sentido tratar esta variable como un número al que se le pueden realizar operaciones matemáticas, dado que la puerta de embarque de un vuelo es una cuestión logística.

Variable	Tipo	Rango / Valores posibles	Descripción
Distancia vuelo	Numérica continua	De 35 a 10.500	Distancia de un vuelo
Ocupacion vuelo	Numérica continua	De 0 a 100, porcentual, con una décima de precisión	Porcentaje de ocupación del fuselaje del avión.
Visibilidad	Numérica continua	De 0 a 30, en kilómetros, con una décima de precisión	Indica cuál es la visibilidad aérea el día del vuelo.

Tiempo estimado de vuelo	Numérica discreta	De 22 a 802	Tiempo en minutos que se estima que durará el vuelo
Demora	Binaria (0/1)	1 si el vuelo se demoró, 0 si no	Etiqueta o variable objetivo. Indica si el vuelo indicado tuvo o no demora.

Variable	Moda	Frecuencia	Descripción
Aeropuerto origen	EZE	2132	Aeropuerto de origen del vuelo
Aeropuerto destino	EZE	2196	Aeropuerto de llegada del vuelo
Horario salida programada	8:15	400	Hora programada de salida del vuelo
Día semana	Viernes	2385	Día de semana de salida del vuelo
Condiciones climáticas	Despejado	6761	Indica la condición del clima al momento del horario de salida del vuelo
Congestión aérea	Baja	6029	Indica el nivel del tráfico
Tipo avión	ATR 72	1760	Indica el modelo del avión del vuelo
Temporada alta	False	9643	Indica si el vuelo se realizó en temporada alta
Puerta de embarque	29	343	Número de la puerta de embarque

2.3 Análisis univariado

En conjunto con la información de la tabla previamente adjunta, se mostrarán, por variable, otros datos relevantes para el análisis. Para las variables categóricas se añadirá un recuento de frecuencias de los distintos valores que puede asumir, en conjunto con un gráfico de barras, también de la frecuencia. Para las numéricas se mostrará un histograma y un boxplot.

Aeropuerto origen




Figura 2.1 Gráfico de barras de aeropuerto origen.

Aeropuerto origen	Cantidad
EZE	2132
BOG	1937
MDE	1565
GRU	1447
PTY	1333

En este gráfico de barras podemos ver como existen ciertos aeropuertos en los cuales la aerolínea tiene mayor incidencia en salidas por sobre el resto, estos son EZE (Ezeiza), BOG (Bogotá), MDE (Antioquia), GRU (São Paulo), y PTY (Panamá), acumulando un total de 8414 salidas sobre el total (15000 registros).

Aeropuerto destino




Figura 2.2 Gráfico de barras de aeropuerto destino.

Aeropuerto destino	Cantidad
EZE	2196
BOG	1827
MDE	1511
GRU	1410
PTY	1259

Con respecto a los aeropuertos de destino, podemos ver que los mismos aeropuertos sobre los cuales hay muchas salidas, a su vez poseen muchas llegadas. En este caso, se acumulan un total de 8203 llegadas sobre el total (15000).

Además, se puede observar que este comportamiento simétrico entre la cantidad de vuelos de llegada y de salida es común en todos los aeropuertos, lo cual indicaría que los mismos mantienen un flujo relativamente

equilibrado entre vuelos de llegada y de salida.

Hora salida programada





Figura 2.3 Gráfico de barras de hora salida programada.

En este gráfico podemos visualizar los horarios en los cuales los vuelos tienen planificada su salida. Podemos ver claramente dos franjas horarias en las cuales hay una mayor salida de vuelos (de 6:00 a 10:00 y de las 13:00 a las 18:00)

Día semana



Día semana	Frecuencia
Viernes	2385
Domingo	2263
Sábado	2243
Miércoles	2149
Jueves	2036
Lunes	1978
Martes	1946

Figura 2.4 Gráfico de barras de aeropuerto Origen.

Referido al gráfico de barras de día semana, podemos ver que los vuelos están distribuidos uniformemente durante la semana, con pocas variaciones entre los diferentes días.

Distancia de vuelo




Figura 2.5 Histograma y boxplot de distancia de vuelo.

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Distancia vuelo	1811.709667	1506.501852	960.0	5.183139e+06	2276.650883	35.0	10050.0	10015.0	2320.0	2.015811

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Distancia vuelo	35.0	135.0	300.0	960.0	2620.0	7720.000	9850.0

El histograma revela una clara concentración de viajes de corta distancia, con una marcada segmentación: la mayoría de los vuelos caen en el rango de corta y media distancia (hasta 5100 km), mientras que existe un salto directo a los vuelos de larga distancia (7300 km o más).

Al analizar el boxplot, si bien los viajes más largos podrían considerarse inicialmente como valores atípicos, un filtrado del dataset para vuelos superiores a 6000 km confirma la existencia de 1098 registros. Esta cifra representa una cantidad significativa de viajes de larga distancia que no son despreciables para el análisis del problema.

Condiciones climáticas

Condiciones climáticas	Frecuencia Absoluta	Frecuencia Relativa
Despejado	6761	0.45
Nublado	3737	0.25
Lluvia	2267	0.15
Tormenta	1175	0.08
Niebla	1060	0.07




Figura 2.6 Gráfico de barras de condiciones climáticas.

En este gráfico podemos observar las condiciones climáticas de los vuelos, que se distribuyen entre 5 categorías: Despejado, Niebla, Lluvia, Tormenta y Nublado. El valor más frecuente es el clima despejado, seguido por nublado; estos juntan el 70% de los datos y representan a las condiciones climáticas más favorables al momento de un vuelo, el 30% restante lo ocupan las condiciones de lluvia, tormenta, y niebla, siendo estos tipos de clima los menos favorables para un vuelo.

Congestión aérea

Congestión aérea	Frecuencia Absoluta	Frecuencia Relativa
Baja	6029	0.4
Media	5978	0.4
Alta	2993	0.2




Figura 2.7 Gráfico de barras de congestión aérea.

La variable `congestion_aerea` representa la cantidad de aviones ocupando el espacio aéreo en el horario estimado del vuelo, podemos ver que tanto la congestión baja y media poseen una frecuencia prácticamente igual, abarcando el 80% de los datos, mientras que la alta congestión es menos frecuente (20%).

Tipo de avión




Figura 2.8 Gráfico de barras de tipo de avión.

En este gráfico se puede observar que la empresa posee en su flota varios modelos de aviones de distintos fabricantes. El avión que la empresa más utiliza en sus vuelos es el ATR 72 con un total de 1760 vuelos (11.7%), seguido del Boeing 737 (1710/11.4%), el Embraer E190 (1708/11.4%), y el Airbus A320 (1664/11%).

Ocupación de vuelo




Figura 2.9 Histograma y boxplot de ocupación de vuelo.

	Media	Media Recor tada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Ocupacion vuelo	71.383 327	72.07 6785	73.4	2.548732 e+02	15.964749	9.2	99.8	90.6	22.7	-0.601515

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Ocupacion vuelo	29.3	42.0	61.1	73.4	83.8	93.605	97.3

Estos gráficos muestran la ocupación total de la cabina de pasajeros de los vuelos. En el histograma, podemos ver una distribución con una asimetría negativa, donde la media es 71.38, y además, dado el comportamiento de esta distribución, toma sentido que los valores más hacia la izquierda, sean considerados outliers en el boxplot.

También, al calcular la cantidad de vuelos cuya ocupación supera el 40%, encontramos que son un total de 14407 vuelos, lo que equivale al 96% de los mismos, dejando solo un 4% (593 registros) de vuelos con baja ocupación.

Temporada alta

Temporada alta	Frecuencia Absoluta	Frecuencia Relativa
False	9643	64.3
True	5357	35.7




Figura 2.10 Gráfico de barras de temporada alta.

En este gráfico se puede observar los vuelos en lo que la aerolínea considera como temporada alta, siendo que la mayoría de los vuelos se realizan en temporada baja, con un total de 9643 viajes sobre el total, abarcando el 64.3% de los datos.

Puerta embarque




Figura 2.11 Gráfico de barras de puerta embarque.

Las puertas de embarque están uniformemente distribuidas, lo que parecería indicar que es una cuestión logística del aeropuerto.

Visibilidad




Figura 2.12 Histograma y boxplot de visibilidad.

En el histograma de visibilidad describe la visibilidad (en kilómetros) del piloto del avión y se observa que está distribuido casi uniformemente con un pico en visibilidad entre 1 y 2 con poco más de 700 vuelos.

Esta uniformidad también es evidente en el diagrama de caja y bigotes (boxplot), el cual muestra una distribución de cajas y bigotes casi idénticas, sin valores atípicos (outliers), y con cuartiles prácticamente equidistantes.

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Visibilidad	15.371927	15.400007	15.6	7.453567e+01	8.633404	0.2	30.0	29.8	14.8	-1.172698

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Visibilidad	0.6	1.5	8.1	15.6	22.9	28.600	29.7

Tiempo estimado de vuelo




Figura 2.13 Histograma y boxplot de tiempo estimado de vuelo.

Este gráfico muestra la duración de los vuelos (en minutos). Se observa una distinción clara entre los vuelos de corta y media distancia (hasta 431 minutos) y los de larga distancia (a partir de 567 minutos). Estos últimos son identificables como valores atípicos (outliers) en el boxplot.

Esta distribución es lógica, dado que el tiempo estimado de un vuelo está directamente correlacionado con la distancia recorrida, lo que explica la similitud en el comportamiento de ambas variables.

	Media	Media Recortada a 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Tiempo de vuelo	169.874467	147.255185	103.0	2.924462e+04	171.010583	22	802	780	162.0	2.009153

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Tiempo de vuelo	29.0	38.0	58.0	103.0	220.0	611.000	774.0

Demora

Demora	Frecuencia Absoluta	Frecuencia Relativa
0	10222	0.6815
1	4778	0.3185




Figura 2.14 Gráfico de barras de demora.

En este gráfico se puede observar lo más importante en este estudio, la cantidad de vuelos con demora del dataset. La mayoría de los vuelos, que es equivalente a $\frac{2}{3}$ del total de vuelos, no tienen demora y los que si tiene demora son un $\frac{1}{3}$ del total.

2.4 Análisis bivariado utilizando la variable objetivo

Este análisis tiene como objetivo explorar el potencial predictivo de cada variable del dataset con respecto a la ocurrencia de demoras. A través de este estudio, se busca identificar qué variables presentan una relación significativa con la variable objetivo, así como detectar posibles umbrales, patrones o categorías que justifiquen reclasificaciones para mejorar el rendimiento de los modelos predictivos.

El análisis se divide en dos secciones: variables continuas y variables categóricas. Para las variables continuas, se evalúa la existencia de umbrales o puntos de corte que permitan segmentar el rango de valores en grupos con comportamientos diferenciados respecto a la demora. Para las variables categóricas, se analiza la proporción de demora en cada categoría y se consideran posibles agrupaciones cuándo categorías similares presentan frecuencias relativas de demora cercanas.

Adicionalmente, se plantean hipótesis sobre posibles relaciones entre variables predictoras que podrían generar redundancia o confusión en los modelos, las cuales serán exploradas en análisis posteriores.

Para la visualización de los resultados se hace uso de gráficos de línea, los cuales permiten identificar fácilmente las desviaciones de la proporción de demora de cada categoría o intervalo respecto de la media global del dataset, representada mediante una línea punteada horizontal. Cabe aclarar que el uso de este formato gráfico no implica continuidad entre las categorías en el caso de variables nominales, ni tampoco asume una relación lineal entre intervalos. Su elección se debe únicamente a la facilidad que brinda para la comparación visual.

Las tablas que contienen los datos utilizados para la construcción de los gráficos están disponibles en la sección Anexo.²

² El desarrollo del análisis bivariado fue excluido del informe final y relegado a la sección de Anexo, junto con las tablas que originalmente constituían el único componente del Anexo. Esto se hizo por la longitud del informe. No obstante, se dejaron las conclusiones del bivariado puesto que estas son de donde se parte para hacer el análisis multivariado.

Desarrollo del análisis bivariado de la Etapa 1

2.4.1 Variables continuas

2.4.1.1 Ocupación de vuelo




Figura 2.15 Línea de ocupación de vuelo contra frecuencia relativa de demora, con intervalos de 5 puntos porcentuales de tamaño.

A partir de los intervalos que poseen al menos 100 observaciones, es decir desde niveles de ocupación superiores al 30%, puede observarse que la proporción de demoras se mantiene relativamente estable y cercana a la media global del dataset, la cual es de 31.85%.

No obstante, los intervalos correspondientes a ocupaciones entre 90%-95% y 95%-100% presentan proporciones de demora aproximadamente 4 y 7 puntos porcentuales superiores a dicha media, respectivamente. Además, estos cuentan con más de 500 observaciones por lo que dicha variación no se la puede atribuir a la varianza propia de intervalos de pocas observaciones, tal y como ocurre con los primeros.

Los resultados sugieren que la variable no tiene un gran poder predictivo sobre la demora para un nivel de ocupación menor al 90%. Sin embargo, para vuelos con una ocupación superior a dicho nivel, la muestra indica que existe una mayor

probabilidad de que se produzca una demora, por lo que la variable si podría tener utilidad predictiva para dichos casos.

Si bien el punto de corte descubierto podría explicarse por la saturación operativa propia de vuelos con un nivel de ocupación muy alta, también podría estar relacionado con la variable “temporada_alta”. Por conocimiento del dominio, se sabe que ambas variables presentan relación tanto con la ocupación del vuelo como con la ocurrencia de demoras. Por lo tanto, es posible que parte del comportamiento observado de mayor ocurrencia de demoras para ocupaciones superiores al 90% se encuentre influenciado por dichas variables y no exclusivamente por la ocupación.

2.4.1.2 Visibilidad




Figura 2.16 Línea de visibilidad contra frecuencia relativa de demora, con intervalos de tamaño 1.

Los intervalos que presentan entre 0 y 5 puntos de visibilidad poseen proporciones de demora superiores al 50%, valor que supera sustancialmente a la media global del dataset (31.85%).

A partir de niveles de visibilidad superiores a 5 puntos, la proporción de demora se estabiliza relativamente cerca de la media global, aunque generalmente entre 3 y 4 puntos porcentuales por debajo de la misma.

La anomalía que se observa con los vuelos de 30 puntos de visibilidad se la puede atribuir a la variabilidad propia de una muestra reducida, como la de dicho intervalo que tan solo contiene 37 observaciones.

En base a los resultados obtenidos, se puede afirmar que la variable visibilidad presenta una gran relación con la ocurrencia de demoras, sobre todo al considerar el umbral de 5 puntos de visibilidad. Además, el gráfico de la figura 2.16 sugiere que

para los vuelos con condiciones de visibilidad no adversas (más de 5 puntos de visibilidad), la proporción de demora del dataset es de 3 a 4 puntos porcentuales menor.

Queda pendiente el análisis conjunto de visibilidad y "condiciones_climaticas" para evaluar posibles redundancias. No obstante, el conocimiento del dominio permite afirmar con bastante seguridad que existe una relación causal entre la visibilidad baja (menor a 5 puntos) y la ocurrencia de demoras.

2.4.1.3 Distancia de vuelo

A pesar de que no corresponde a esta sección, resulta importante remarcar que existe un coeficiente de correlación extremadamente alto (0.999) entre las variables "distancia_vuelo" y "tiempo_estimado_vuelo". Para no incurrir en un análisis redundante, se trabajará solamente con la variable "distancia_vuelo". La elección de esta variable se debe a la posibilidad de aportar mayor información interpretativa gracias a su relación directa con la variable "ruta_aérea".




Figura 2.17 Línea de distancia de vuelo contra frecuencia relativa de demora, con intervalos de 500 millas.

La proporción de demora se mantiene considerablemente estable en torno a la media global de 0,3185. Se observa que a partir de los vuelos de 3000 millas existe un ligero incremento en la misma, como así también en la zona de 8500-9000 millas. Sin embargo, en los vuelos con distancias mayores a 7000 millas los intervalos construidos contienen relativamente pocas observaciones, por lo que pueden verse más afectados por la varianza.

Lo que resulta interesante de los datos expuestos, es el hecho de que los 5 intervalos con mayor proporción de demora, los cuales tienen proporciones superiores al 35%, corresponden a vuelos de largas distancias (+3500 millas).

Esto indica la posibilidad de que los vuelos de larga distancia estén relacionados con la ocurrencia de una demora. Sin embargo, también se observan intervalos que poseen una baja proporción de demora y que pertenecen a vuelos de largas distancias.

Intervalo	Proporción de demora	Observaciones
0 -1800	0.313743	10209
1800 - 3500	0.324554	2240
3500+	0.332419	2551

Tabla 2.1 Proporción de demora por intervalo de distancia vuelo con la variable reclasificada.

Para continuar explorando la idea anterior, se agruparon las observaciones en tres valores de distancia: Baja, Media y Alta. Si bien dichos intervalos presentan una proporción de demora que crece con la distancia, esta tendencia es muy débil como para afirmar que existe una relación.

En definitiva, los resultados sugieren que no hay una relación fuerte entre los vuelos de larga distancia y la demora. No obstante, el hecho de que los 5 intervalos con mayor proporción de demora correspondan a distancias de vuelos específicas, podría ser indicador de que existen aeropuertos o rutas aéreas que presentan una frecuencia relativa de demoras mayor. Dicha hipótesis será abordada más adelante dentro del estudio del presente trabajo.

2.4.2 Variables categóricas

2.4.2.1 Horario de salida

Esta variable categórica cuenta con 94 valores únicos de 96 posibles. Debido al elevado número de categorías posibles, primero se intenta utilizar dos criterios de reclasificación para reducir dicho número con el objetivo de encontrar alguna relación entre el horario de salida y la demora. Con el primer criterio, se reclasificó la variable en 3 valores: Mañana, Tarde y Noche.

Intervalo	Proporción de demora	Observaciones
Mañana (6:00 - 14:00)	0.316720	7865
Tarde (14:00 - 22:00)	0.326723	5194
Noche (22:00 - 6:00)	0.303967	1941

Tabla 2.2 Proporción de demora por intervalo de horario de salida con la variable reclasificada según momento del día.

Con el segundo criterio, se reclasificó la variable también en 3 valores: Pico matutino , Pico vespertino , Horario normal. Siendo ambos picos las franjas horarias que concentran la mayor cantidad de vuelos, contruidos a partir de cuartos de horas adyacentes con más de 300 observaciones, patrón observable en el gráfico de barras del análisis univariado.

Intervalo	Proporción de demora	Observaciones
Pico matutino (07:00-09:00)	0.303161	3005
Pico vespertino (14:00-15:45)	0.321110	2127
Horario normal	0.322659	9868

Tabla 2.3 Proporción de demora por intervalo de horario de salida con la variable reclasificada según los picos de tráfico.

Con ambos criterios de reclasificación se observa que la proporción de demora se mantiene constante. Por lo que en principio se descarta alguna relación entre el horario de salida y la ocurrencia de una demora.

Sin embargo, la agrupación de horarios en intervalos amplios podría ocultar comportamientos particulares en franjas horarias más específicas. Por lo tanto, se

intenta analizar los horarios de salida sin reclasificar, pero utilizando sólo aquellos que cuenten con más de 100 observaciones para mitigar la variabilidad natural de las muestras pequeñas.

Hora de salida	Proporción de demora	Observaciones
11:15	0.401639	122
06:45	0.387665	227
18:30	0.382353	102
17:45	0.371585	183
09:15	0.361446	249
15:45	0.359736	303
12:45	0.353659	164
15:15	0.344633	354
14:15	0.343234	303
06:00	0.342373	295
16:15	0.341772	237
14:30	0.340984	305
06:30	0.340164	244
08:30	0.339572	374
09:45	0.338290	269
10:00	0.337349	166
14:45	0.335616	292
12:00	0.333333	162
11:45	0.333333	129
17:15	0.329341	167
09:00	0.325342	292
09:30	0.323420	269
11:30	0.323077	130
10:15	0.322981	161

05:15	0.322148	149
08:00	0.321429	364
17:30	0.321244	193
13:00	0.320988	243
08:45	0.320442	362
05:45	0.317881	151
05:30	0.315385	130
08:15	0.315000	400
07:30	0.313830	376
13:15	0.313559	236
05:00	0.309677	155
14:00	0.307958	289
13:45	0.306306	222
13:30	0.301527	262
07:15	0.300000	370
18:45	0.300000	110
16:30	0.298755	241
15:00	0.298305	295
16:00	0.298165	218
16:45	0.297959	245
06:15	0.297959	245
17:00	0.297143	175
10:30	0.293333	150
10:45	0.289941	169
12:15	0.288591	149
12:30	0.272189	169
11:00	0.272059	136

07:00	0.270408	392
15:30	0.269896	289
07:45	0.245232	367

Tabla 2.4 Proporción de demora por hora de salida, ordenada por proporción descendente y filtrada por categorías con más de 100 observaciones.

La tabla 2.4 muestra un hallazgo interesante, parecería que si existe algún patrón entre la hora de salida y la demora. Esto se evidencia a partir de que las primeras cinco horas de salida tienen de 4.2 a 8 puntos porcentuales más que la media global, y las cinco últimas horas de salida tienen entre 4.6 y 7.3 puntos porcentuales menos que la misma.

Sin embargo, la ausencia de diferencias en las reclasificaciones por franjas horarias amplias, sumado a que las horas con mayor y menor proporción de demora no son adyacentes entre sí, sugiere que no existe una relación temporal directa entre el horario de salida y la ocurrencia de demoras. Se teoriza que las diferencias observadas son efectos indirectos de otras variables o por datos no capturados dentro del dataset.

A pesar de la alta cardinalidad (94 categorías) y la ausencia de un patrón temporal coherente, se mantendrá esta variable en la vista minable para su evaluación durante el modelado, aunque se anticipa que presentará dificultades debido a la alta dimensionalidad que genera debido al uso de variables dummy. Se evaluará también la posibilidad de reclasificar esta variable en un número reducido de categorías en caso de que su versión original no aporte valor predictivo. En caso de no contribuir al desempeño de los modelos o generar overfitting, será excluida.

2.4.2.1 Día de la semana




Figura 2.18 Línea de día de semana contra frecuencia relativa de demora.

Los resultados sugieren que en general, el día de la semana no tiene demasiado poder predictivo, dado que la proporción de demora se mantiene relativamente constante en torno a la media del dataset. Los únicos días donde hay una variación relevante respecto de la media global (alrededor de 2.5 puntos porcentuales), son los días jueves y viernes. Si bien esta diferencia no parece lo suficientemente grande como para afirmar la existencia de una relación fuerte, podría reflejar patrones específicos de tráfico aéreo asociados a los días jueves y viernes.

2.4.2.2 Condiciones climáticas

Condiciones climáticas	Proporción de demora	Observaciones
Tormenta	0.621277	1175
Niebla	0.461321	1060
Lluvia	0.367005	2267
Despejado	0.265493	6761
Nublado	0.249398	3737

Tabla 2.5 Proporción de demora por día de semana, ordenada por proporción descendente.




Figura 2.19 Línea de condiciones climáticas contra frecuencia relativa de demora.

En base a lo observado en la tabla y las figuras, y siendo que cada categoría cuenta con más de 1000 observaciones, se puede concluir que la variable “condiciones_climaticas” cuenta con un fuerte poder predictivo sobre la demora.

No obstante, conviene señalar el hecho de que por conocimiento del dominio, se sabe que muy probablemente esta variable está fuertemente ligada a la variable “visibilidad”, que también vimos que tenía peso en la predicción de la demora. Por lo tanto, conviene analizar ambas variables en conjunto para evaluar si realmente aportan información diferente.

Además, debido a la baja diferencia de frecuencia relativa de demora entre las categorías nublado y despejado (1,6 puntos porcentuales) , en modelos como LDA podría ser conveniente agrupar ambos valores para evitar crear dos variables dummy que aporten poca información diferente en lo que respecta a discriminación de clases.

2.4.2.3 Congestión aérea

Congestión aérea	Proporción de demora	Observaciones
Alta	0.467758	2993
Media	0.327367	5978
Baja	0.235694	6029

Tabla 2.6 Proporción de demora por congestión aérea.




Figura 2.20 Línea de congestión aérea contra frecuencia relativa de demora.

Los resultados muestran una relación clara entre la congestión aérea y la ocurrencia de demoras. A medida que aumenta el nivel de congestión, también aumenta la proporción de demora. Mientras que los vuelos con congestión baja presentan una proporción de demora cercana al 23.5%, los vuelos con congestión alta alcanzan valores cercanos al 47%, es decir, aproximadamente 15 puntos porcentuales por encima de la media global del dataset.

Además, todas las categorías cuentan con una elevada cantidad de observaciones, por lo que las diferencias observadas no pueden atribuirse a la variabilidad propia de muestras pequeñas. En base a ello, se puede afirmar que la variable “congestion_aerea” posee un fuerte poder predictivo sobre la ocurrencia de demoras.

Por conocimiento del dominio, también resulta razonable asumir que esta variable podría encontrarse relacionada con otras previamente analizadas, como “condiciones_climaticas”, y que por lo tanto conviene analizarlas en conjunto para estudiar si aportan información redundante.

2.4.2.4 Temporada alta

Temporada alta	Proporción de demora	Observaciones
Verdadero	0.380437	5357
Falso	0.284144	9643

Tabla 2.7 Frecuencia relativa de demora por temporada.

Los resultados muestran que los vuelos correspondientes a temporada alta presentan una proporción de demora considerablemente superior a la de temporada baja, con una diferencia cercana a 10 puntos porcentuales. Además, ambas categorías cuentan con una elevada cantidad de observaciones, por lo que la diferencia observada no se debe a la variabilidad muestral. En base a ello, se puede afirmar que la variable “temporada_alta” presenta una fuerte relación con la ocurrencia de demoras.

2.4.2.5 Tipo de avión

Tipo de avión	Proporción de demora	Observaciones
Airbus A330	0.359551	712
Embraer E195	0.329554	1323
Airbus A350	0.328125	704
Boeing 737	0.327485	1710
Boeing 757	0.324704	1352
Boeing 737 MAX	0.323029	1294
Boeing 787	0.321981	646
Boeing 777	0.318710	775
ATR 72	0.312500	1760
Airbus A320neo	0.309911	1352
Embraer E190	0.300937	1708
Airbus A320	0.300481	1664

Tabla 2.8 Frecuencia relativa de demora por tipo de avión, ordenada por proporción descendente.




Figura 2.21 Línea de tipo de avión contra frecuencia relativa demora.

Los resultados exponen que el tipo de avión no tiene gran influencia en la ocurrencia de demoras, puesto que la proporción de demora se mantiene estable en torno a la media global para casi todos los aviones. La única excepción a dicho comportamiento es el tipo de avión “Airbus A330”, debido a que los vuelos realizados con este presentan una proporción de demora 4,1 puntos porcentuales por encima de la media del dataset.

En consecuencia, similar a lo observado con “ocupacion_vuelo”, en la mayoría de las categorías la variable bajo estudio no posee un poder predictivo elevado para la ocurrencia de demoras. No obstante, existe una categoría en la que se observa una mayor frecuencia relativa de demoras, por lo que podría resultar útil considerar dicha situación en particular.

2.4.2.6 Puerta de embarque




Figura 2.22 Línea de puerta de embarque contra frecuencia relativa demora.

La variable "puerta_embarque" presenta diferencias en la proporción de demora entre categorías (25.4% a 37.3%). Sin embargo, en etapas posteriores de este estudio no se identificó una justificación causal clara que explique por qué la puerta asignada influiría directamente en la demora. A pesar de su alta cardinalidad (49 categorías), se mantendrá en la vista minable para su evaluación durante el modelado, aunque se anticipa que su aporte predictivo será limitado. En caso de no contribuir al desempeño de los modelos o generar overfitting, será excluida.

2.4.2.7 Aeropuerto de origen y Aeropuerto de destino




Figura 2.23 Línea de aeropuerto de origen contra demora.




Figura 2.24 Línea de aeropuerto de destino contra demora.





Figura 2.25 Gráficos filtrados por aeropuertos con al menos 100 observaciones.

Los gráficos de la figura 2.25 evidencian distintos fenómenos relevantes. En primer lugar, incluso teniendo en cuenta sólo los aeropuertos con al menos 100 observaciones, existe una importante dispersión de las frecuencias relativas de la demora respecto de la media del dataset. Sin embargo, en el caso de los cinco aeropuertos de origen y destino que concentran la mayor cantidad de vuelos

(Ezeiza, Bogotá, Antioquia, São Paulo y Panamá), esto no sucede puesto que presentan una frecuencia relativa de demoras muy cercana a la media global. En principio, los resultados indicarían que el aeropuerto de origen y destino tienen influencia sobre la ocurrencia de demoras, aunque dicha relación no parece ser uniforme en todos los casos.

Luego, se puede observar que, en alguno de los casos, los aeropuertos de origen que tienen una proporción de demora considerablemente superior al de la media global experimentan exactamente lo opuesto cuando ofician de aeropuerto de destino. Por ejemplo, los aeropuertos de Miami, Madrid y Mendoza.

Sin embargo, en otros aeropuertos sucede que cuando son de origen tienen una proporción de demora alta y la mantienen cuando son de destino. O también sucede que a veces tienen una proporción de demora alta o baja en alguna categoría y luego en la categoría contraria tienen una demora similar a la de la media del dataset.

En base a estas últimas ideas, sumado al conocimiento del dominio, resulta razonable suponer que el aeropuerto de origen podría tener una relación más directa con la ocurrencia de una demora, dado que gran parte de los procesos operativos previos al vuelo ocurren en dicha instancia. Sin embargo, para explicar el comportamiento en el resto de situaciones, se teoriza que existen influencias de otras variables como la congestión aérea, las condiciones climáticas, las rutas aéreas o incluso factores de los cuales no se tiene información. Se intentará explorar esta hipótesis en el análisis multivariado.

2.4.3 Conclusiones del análisis bivariado

El análisis bivariado permitió identificar las variables con mayor poder predictivo sobre la ocurrencia de demoras, así como detectar umbrales y patrones relevantes para el modelado posterior.

Variables con fuerte poder predictivo:

- **Condiciones climáticas:** Muestra una relación clara con la demora. Las categorías "Tormenta" y "Niebla" presentan proporciones de demora significativamente superiores (62% y 46% respectivamente) a la media global (31.85%). Se identificó la posibilidad de agrupar las categorías "Nublado" y "Despejado" (diferencia de solo 1.6 puntos porcentuales) en modelos paramétricos como LDA o regresión logística, para evitar generar variables dummy redundantes.
- **Visibilidad:** Presenta un umbral claro en 5 puntos de visibilidad. Por debajo de este valor, la proporción de demora supera el 50%, mientras que por encima se estabiliza cerca del 28%. Este umbral podría utilizarse para crear una variable binaria derivada. No obstante, resta descartar su redundancia con condiciones climáticas.
- **Congestión aérea:** Muestra una relación fuerte con la demora. Los vuelos con congestión alta presentan una proporción de demora del 47%, mientras que los de congestión baja tienen un 23.5%. Esta variable ordinal es adecuada para todos los modelos considerados.
- **Temporada alta:** Presenta una diferencia de aproximadamente 10 puntos porcentuales entre temporada alta (38%) y temporada baja (28.4%), lo que sugiere un fuerte poder predictivo.

Variables con poder predictivo moderado o condicional:

- **Ocupación de vuelo:** Solo muestra relevancia predictiva para niveles de ocupación superiores al 90%, donde la proporción de demora aumenta notablemente. Esto sugiere la creación de una variable binaria (ocupación > 90%) que podría ser útil en árboles de decisión o como término de interacción en regresión logística.
- **Aeropuerto de origen y destino:** Presentan patrones heterogéneos, aunque varios aeropuertos principales muestran proporciones de demora cercanas a la media general. Debido a la alta cardinalidad de ambas variables, su inclusión directa en modelos como LDA o regresión logística podría generar problemas de dimensionalidad y aumentar la complejidad del modelo.

Además, origen y destino representan parcialmente la misma información que la ruta aérea. Por este motivo, se decidió reemplazarlas por la variable ruta_aerea, que permite conservar la información operativa del trayecto en una única variable categórica más representativa y potencialmente más predictiva de las demoras.

- **Tipo de avión:** En general no muestra gran poder predictivo, excepto por el "Airbus A330" que presenta 4.1 puntos porcentuales por encima de la media. Podría considerarse una variable binaria ("Airbus A330" vs "Otros") para capturar este efecto específico.

Variables con bajo poder predictivo:

- **Distancia de vuelo:** No presenta una relación clara con la demora a nivel agregado, aunque se observa que los 5 intervalos con mayor proporción de demora corresponden a vuelos de larga distancia. Esto sugiere que la distancia en sí no es predictiva, pero podría estar capturando efectos de rutas aéreas específicas.
- **Horario de salida:** A pesar de observarse diferencias entre horarios específicos, la ausencia de un patrón temporal coherente y la estabilidad en las reclasificaciones por franjas horarias sugieren que el horario en sí no tiene poder predictivo. Las diferencias observadas probablemente se deben a efectos confundidos con otras variables como rutas o congestión.
- **Puerta de embarque:** Muestra variabilidad en la proporción de demora entre categorías (25.4% a 37.3%), pero sin un patrón claro, podría atribuirse simplemente a ser una relación espuria.
- **Día de la semana:** Presenta una variación mínima en torno a la media (alrededor de 2.5 puntos porcentuales de diferencia entre el mejor y peor día), lo que sugiere bajo poder predictivo.

Consideraciones para el análisis multivariado:

Se identificaron posibles redundancias entre variables que requieren análisis conjunto: "condiciones_climáticas" y "visibilidad", "congestión_aérea" y "condiciones_climáticas". Estos análisis permitirán determinar si aportan información complementaria o si sería conveniente seleccionar solo una de ellas para evitar multicolinealidad en modelos paramétricos.

2.5 Análisis multivariado

En las secciones anteriores, quedaron abiertos ciertos interrogantes:

- ¿Por qué existen ciertos horarios de salida no agrupables en franjas con mayor proporción de demoras?
- ¿Por qué existen puertas de embarque con mayor proporción de demoras?
- ¿Por qué existen distancias de vuelo con mayor proporción de demoras?

Además, se hizo mención de la utilidad de analizar las siguientes variables en conjunto:

- Aeropuerto de origen y aeropuerto de destino, por medio de la variable derivada ruta aérea.
- Condiciones climáticas y congestión aérea.
- Condiciones climáticas y visibilidad.
- Temporada alta y ocupación de vuelo.
- Distancia de vuelo y ruta aérea.
- Horario de salida y ruta aérea.
- Puerta de embarque y ruta aérea.

Debido a la extensión que ya posee la etapa del análisis bivariado, solo se expondrá el análisis de las primeras tres, y se hará una breve mención de los resultados del resto de la lista y de otras no mencionadas previamente.

2.5.1 Ruta aérea

2.5.1.1 Desarrollo

Ruta aérea (única)	Proporción de demora	Observaciones
BOG-JFK	0.454545	121
GRU-MIA	0.434426	122
BOG-EZE	0.432836	134
BOG-MAD	0.394231	104
EZE-GRU	0.386905	168
CCS-PTY	0.252475	202
BGA-BOG	0.250825	303
EZE-MDE	0.25	56
GRU-MVD	0.241176	170
CDG-GRU	0.215686	102

Tabla 2.9 Rutas únicas destacadas, ordenadas por proporción de demora descendente.




Figura 2.26 Asimetría entre las rutas aéreas ordenadas³.

³ La definición de ruta ordenada se encuentra en la sección 3.2.1.

En base a la tabla 2.9 y la figura 2.26 se pueden analizar distintas cuestiones. La variable ruta aérea muestra variabilidad relevante en la proporción de demora, lo que sugiere potencial valor predictivo. Además, casi la totalidad de sus clases cuentan con más de 100 observaciones por lo que dicha variabilidad no parece ser atribuible a lo esperado en muestras pequeñas.

Resulta interesante el hecho de que existen aeropuertos que no tenían una frecuencia de demora particularmente alta como JFK y BOG pero que al ser observados en conjunto como ruta, terminan presentando una ocurrencia de demoras mucho mayor.

No obstante, se debe tener precaución, ya que se puede constatar lo mismo que se detectó en la sección 2.4.2.7: muchas de las rutas poseen una asimetría importante, siendo el caso más acentuado el de las rutas ordenadas CCS-EZE y EZE-CCS.

Ruta ordenada	Proporción de demora	Observaciones
EZE-CCS	0.537037	54
CCS-EZE	0.231884	69

Tabla 2.10 Ruta asimétrica.

Esto genera que observar la variable “ruta_aerea_unica” pueda conducir a conclusiones incorrectas, debido a que se podría tener una proporción de demora relativamente elevada como EZE-CCS (0.365) y en realidad depender fuertemente del sentido del vuelo.

Sin embargo, es importante remarcar que la presencia de asimetría en las rutas no implica necesariamente un problema en términos analíticos. Existen casos en los cuales, independientemente del sentido del vuelo, la ruta mantiene una proporción de demora por encima o por debajo de la media del dataset. Enumerando los cuadrantes de la figura 2.26 en sentido horario, se puede ver que en los cuadrantes 2 y 4 están las rutas asimétricas problemáticas.

Adicionalmente, la variable “ruta_aerea_ordenada” tiene relativamente pocas observaciones por ruta, siendo que la mayoría tiene menos de 80, por lo que las asimetrías también son influenciadas por el tamaño de la muestra.

En resumen, la variable “ruta_aerea_ordenada” posee muy pocas observaciones por categoría como para ser utilizada en los modelos. La variable “ruta_aerea_unica” no presenta ese problema y tiene el potencial de poseer utilidad predictiva. Si bien la presencia de rutas asimétricas problemáticas como las que se pueden ver en los cuadrantes 2 y 4 de la figura 2.26, limitan la capacidad predictiva de la variable, de todas formas “ruta_aerea_unica” captura de forma más efectiva la variabilidad en la proporción de demora que las variables de aeropuerto de origen y destino por separado.

Considerando que “aeropuerto_origen” y “aeropuerto_destino” presentan alta cardinalidad y que sus efectos sobre la demora no son uniformes ni independientes entre sí, se decide utilizar “ruta_aerea_unica” en reemplazo de ambas variables de aeropuerto. Esta decisión reduce la dimensionalidad del problema y permite capturar de manera más directa el efecto combinado del par origen-destino sobre la demora. La variable “ruta_aerea_ordenada” se descarta definitivamente debido a la insuficiencia de observaciones por categoría.

2.5.1.2 Outliers

Prácticamente la totalidad de las rutas aéreas son coherentes desde el punto de vista de la distancia entre aeropuertos. Sin embargo, la ruta aérea única “EZE-AEP” con 562 registros, constituye una categoría atípica, puesto que ambos aeropuertos se encuentran en la misma ciudad y las fuentes investigadas confirman que no existen vuelos comerciales entre ambos puntos.

Sin embargo, existen vuelos no comerciales llamados “vuelos ferry / vuelos de posicionamiento” que pueden ser factibles. Para no caer en conclusiones apresuradas, se llevan a cabo los siguientes análisis.




Figura 2.27 Tipos de avión según distancia de vuelo.

Tipo de avión	Capacidad	Frecuencia absoluta	Frecuencia relativa
Airbus A320	140-180	126	22.42
ATR 72	68-78	139	24.73
Boeing 737	126-189	143	25.44
Embraer E190	96-114	154	27.4

Tabla 2.11 Tipos de avión utilizados en la ruta única EZE-AEP.




Figura 2.28 Boxplot de ocupación con los registros de la ruta atípica.

Los tipos de avión utilizados en vuelos de corta distancia dentro del dataset, coinciden con los cuatro tipos de avión utilizados para la ruta EZE-AEP. Esto impide descartar de forma inmediata dichos registros puesto que mantienen consistencia con los tipos de avión asociados a rutas cortas.

No obstante, resulta extraño que aviones con gran capacidad como el AirbusA320 y el Boeing 737 sean usados para vuelos ferry. Sobre todo teniendo en cuenta la relativamente alta cantidad de vuelos, siendo que en la práctica cotidiana este tipo de vuelos se realiza de forma muy esporádica, mientras que en el dataset ocurren a una tasa de 1.5 vuelos por día o 47 vuelos por mes.

A todo eso, se le suma el hecho de que el 95% de los vuelos de la ruta tienen una ocupación superior al 40%. Característica incongruente en los vuelos ferry que suelen ir relativamente vacíos.

En resumen, si bien los vuelos realizados con el tipo de avión “ATR 72” podrían llegar a ser consistentes debido a su capacidad de pasajeros reducida, de todas formas presentan la incongruencia de la ocupación elevada. El resto de vuelos con los otros tipos de avión, no parecen plausibles por su capacidad de pasajeros y su tasa de ocupación.

En conclusión, los 562 registros de la ruta EZE-AEP (3.75% del dataset) presentan particularidades operativas: alta frecuencia de vuelos entre aeropuertos de la misma ciudad, ocupación elevada (95% superior al 40% de ocupación), y uso de aeronaves de gran capacidad. Sin embargo, al analizar el resto de las variables, todas distribuyen de forma consistente con el dataset completo, incluyendo la variable objetivo (30.43% vs 31.8% de demora global).

Dado que la única anomalía observable es la combinación de aeropuertos y que el resto de las variables distribuyen igual que en el dataset completo, se decide mantener estos registros. Idealmente deberían validarse con el cliente, pero ante la ausencia de errores concretos en otras variables, se prefiere mantenerlos para contar con mayor cantidad de registros de entrenamiento y validación.

2.5.2 Congestión aérea y Condiciones climáticas

	Baja	Media	Alta	Total
Despejado	2715	2688	1358	6761
Nublado	1518	1474	745	3737
Lluvia	907	914	446	2267
Niebla	421	428	211	1060
Tormenta	468	474	233	1175
Total	6029	5978	2993	15000

Tabla 2.12 Tabla de contingencia de las variables “congestion_aerea” y “condiciones_climaticas”.

En base al conocimiento del dominio, se sospechaba que la congestión aérea podría verse influenciada por las condiciones climáticas. No obstante, en la tabla de contingencia se puede ver claramente que todas las filas poseen una distribución extremadamente similar entre sí y que coincide con la detectada en el análisis univariado (40% baja, 40% media y 20% alta), lo que indica que dentro de la muestra, las condiciones climáticas no tienen efecto en la congestión aérea.

Para formalizar el resultado observado, se realiza una prueba de chi-cuadrado.

PRUEBA CHI-CUADRADO	
Chi-cuadrado χ^2	0.8877
p-value	0.998863
Grados de libertad	8

Tabla 2.13 Resultados de la prueba chi-cuadrado.

Como se puede ver a partir de los resultados de la prueba chi-cuadrado, bajo el supuesto de que las variables son independientes, la probabilidad de obtener un χ^2 igual o superior al observado era del 99,8%. Es decir, bajo la hipótesis nula es altamente probable obtener el estadístico observado.

En conclusión, no se rechaza la hipótesis nula y la evidencia empírica de que las variables son independientes resulta lo suficientemente fuerte como para aceptar la independencia.




Figura 2.29 Mapa de calor de la proporción de demora por dupla de las variables analizadas.

La figura 2.29 reafirma lo que se espera de dos variables con gran poder predictivo sobre la demora e independientes entre sí. Las frecuencias relativas de demora por dupla resultan confiables puesto que todas las duplas presentan al menos 200 observaciones.

En conclusión, el uso de ambas variables no introduce redundancia de información para predecir la variable objetivo y su uso conjunto parece ser un buen predictor de la ocurrencia de demoras.

2.5.3 Condiciones climáticas y visibilidad




Figura 2.30 Gráfico de dispersión categórico de las variables bajo estudio.

Rango de visibilidad	Condiciones climáticas presentes
5-30	Despejado, Nublado y Lluvia
0-5	Niebla y Tormenta
0-3	Niebla y Tormenta
3-5	Solo Tormenta

Tabla 2.14 Observaciones a partir del gráfico de dispersión.

La tabla anterior exhibe hallazgos importantes. El umbral de 5 puntos de visibilidad que separa fuertemente la frecuencia relativa de demoras, se corresponde con las

categorías de la variable "condiciones_climaticas". En el sentido de que las dos que tienen mayor frecuencia relativa de demoras (Tormenta y Niebla), son las únicas dos categorías que tienen registros con menos de 5 puntos de visibilidad.

Pero existe algo aún más relevante. En el análisis bivariado se había detectado que el rango 0-3 de visibilidad tenía una frecuencia relativa de demoras inferior al que tenía el rango 3-5 ([ver figura 2.16](#)). Lo cual, bajo la hipótesis de que la visibilidad reducida tenía una relación de causalidad directa con la demora, resultaba incoherente.

Rango de visibilidad	Promedio ponderado	Observaciones
0-3	0.5245	1669
3-5	0.6108	555

Tabla 2.15 Rangos de visibilidad relevantes.

La figura 2.30 explica esa situación. Lo que sucede es que en el rango 0-3, hay vuelos con la categoría "Niebla" y "Tormenta", mientras que en el rango 3-5 solo hay vuelos con la categoría "Tormenta". Como la categoría "Niebla" tiene una proporción de demora inferior a la de "Tormenta", genera el declive de la proporción de demora en el intervalo de visibilidad 0-3.

Si la visibilidad realmente fuera la variable con mayor peso predictivo, entonces no debería observarse el comportamiento expuesto.

Estos resultados constituyen una evidencia empírica de que "condiciones_climaticas" contiene toda la información de "visibilidad" y además aporta discriminación adicional (separa Niebla 46.1% de Tormenta 62.1%, que "visibilidad" agrupa en el rango 0-5). Se decide mantener ambas en la vista minable, pero se anticipa que "visibilidad" será excluida en la mayoría de los modelos por ser redundante e inferior en poder predictivo.

2.5.4 Temporada alta y ocupación de vuelo




Figura 2.31 Boxplot de ocupación de vuelo por temporada alta

Métrica	Temporada Baja	Temporada Alta
Total de vuelos	9643	5357
Vuelos en P90-100 (>90.7%)	972	544
Ocupación media general	71.31%	71.52%
% vuelos en P90-100	10.08%	10.15%
Ocupación media en P90-100	94.06%	93.79%
Proporción de demora (general)	28.41%	38.04%

Tabla 2.16 Estadísticas de ocupación de vuelo según tipo de temporada.

La tabla 2.16 permite refutar la hipótesis de que el aumento en la frecuencia relativa de demoras en vuelos con ocupación mayor al 90% se debía a la temporada alta. Los datos muestran que en ambos tipos de temporada, la proporción de vuelos con 90% o más de ocupación es prácticamente idéntica (10.08% vs 10.15%). Esto resulta relevante puesto que nos permite estar seguros de que ambas variables aportan información diferente a la hora de predecir las demoras.

Además, el boxplot de la figura 2.31 permite observar que la distribución de la ocupación de los vuelos es prácticamente idéntica entre temporada alta y baja. Las medianas, los rangos intercuartílicos y los bigotes son prácticamente equivalentes en ambos grupos, lo que sugiere una independencia entre el nivel de ocupación de los vuelos y el tipo de temporada.

2.5.5 Otras variables

Se deja constancia de que se construyó una matriz de correlación con el objetivo de explorar posibles relaciones lineales no contempladas. No obstante, los resultados concluyeron que ninguna de las variables posibles tenía un coeficiente de correlación alto, a excepción de la dupla “distancia_vuelo” y “tiempo_estimado_vuelo”. Estos resultados eran esperables puesto que solo había 3 variables continuas, 2 binarias y 2 ordinales (se trató “condiciones_climaticas” como ordinal según que tan adverso era el clima). Por lo general, este tipo de análisis conduce a resultados más satisfactorios cuando la mayoría de las variables son continuas, puesto que las variables ordinales codificadas no tienen la misma precisión.

De todas formas, que una dupla de variables no presenten un coeficiente de correlación alto no implica que no estén relacionadas de alguna forma. Un ejemplo de ello es la relación descubierta entre “visibilidad” y “condiciones_climaticas”.

2.5.5.1 Distancia de vuelo y Tiempo estimado de vuelo




Figura 2.32 Gráfico de dispersión de las variables bajo estudio.

Como se había adelantado, el coeficiente de correlación de Pearson entre las variables de esta sección es de 0,999. Resultado que se condice con la relación lineal positiva perfecta que se ve en la figura 2.32.

Debido al coeficiente extremadamente alto, ambas variables aportan información prácticamente equivalente. En consecuencia, la utilización conjunta de ambas podría introducir redundancia de información dentro de los modelos predictivos. Es así, que se elige excluir de la construcción de los modelos a la variable “tiempo_estimado_vuelo” puesto que se entiende que es derivada de la variable “distancia_vuelo”.

Como observación adicional, se menciona el hecho de que para una cierta ruta aérea, siempre se registra la misma distancia de vuelo. No obstante, el tiempo estimado de vuelo tiende a oscilar levemente dentro de un rango cercano a su media. Esto genera bandas verticales de puntos en el gráfico de dispersión, correspondientes a distancias fijas con tiempos estimados levemente variables .

2.5.5.2 Ruta aérea y otras variables

Debido a la alta cardinalidad presentes en las variables de rutas aéreas, puertas de embarque y horarios de salida, el análisis de sus interacciones mediante métodos bivariados no arrojó resultados concluyentes. En consecuencia, se decide excluir del análisis exploratorio las hipótesis de asociación entre estos factores.

No obstante, en lo que respecta a la relación entre las rutas aéreas y la variable “distancia_vuelo”, se lograron obtener resultados concluyentes expuestos en la figura 2.32.

Rango de distancia de vuelo	Proporción de demora	Observaciones
8535 - 9035	0.394231	104
9035 - 9535	0.260274	219

Tabla 2.17 Rangos de distancia de vuelo relevantes.

Como se puede ver en el gráfico, la razón por la cual el primer intervalo presenta una proporción de demora tan elevada se debe a que sólo contiene a la ruta aérea BOG-MAD, la cual exhibe la misma frecuencia relativa de demoras. Mientras que el segundo, contiene dos rutas aéreas con proporciones de demora muy bajas.

En definitiva, se concluye que la variabilidad observada en las proporciones de demora entre los distintos intervalos de distancia de vuelo no se debe a la distancia en sí misma, sino a las rutas aéreas que componen cada intervalo. Esto indica que gran parte de la información aportada por la variable “distancia_vuelo” ya se encuentra representada por la variable “ruta_aerea”, motivo por el cual se considerará su posible exclusión durante la etapa de preprocesamiento según el modelo utilizado.




Figura 2.33 Mapa de calor de frecuencia relativa de demora por dupla de variables “ruta_aerea” y “distancia_estimada_vuelo”.

3 Fase de preparación de Datos

3.1 Limpieza

En lo que respecta a el análisis univariado, se verificó la inexistencia de valores nulos o registros incompletos, observándose que los 15.000 registros presentaban datos válidos en todas las variables analizadas.

Asimismo, se comprobó que no existían identificadores duplicados dentro del dataset.

Además, no se detectaron outliers univariados que justificaran corrección o eliminación de registros. Los casos más alejados del comportamiento general correspondieron a algunos vuelos con niveles de ocupación entre 8% y 15%. Sin embargo, dichos valores resultan razonables dentro del contexto operacional y fueron conservados.

En cuanto al análisis multivariado, no se detectaron inconsistencias relevantes entre las variables “distancia_vuelo” y “tiempo_estimado_vuelo”, ni entre “distancia_vuelo” y “tipo_avion”.

Tampoco se identificaron combinaciones incompatibles entre “visibilidad” y “condiciones_climaticas”. Por ejemplo, no se registraron casos de tormenta o niebla acompañados de niveles elevados de visibilidad.

Se detectó una ruta aérea atípica, situación que puso en duda la validez de 562 registros. Sin embargo, se decidió mantenerlos. La justificación correspondiente se desarrolla en detalle en la sección 2.5.1.2.

Finalmente, se realizaron algunas adecuaciones orientadas a facilitar el procesamiento y posterior modelado de los datos:

- Se eliminaron los acentos en las categorías de la variable “dia_semana”.
- Se reemplazó la coma decimal por punto decimal en las variables “ocupacion_vuelo” y “visibilidad”, para facilitar el trabajo con IBM Modeler y con los archivos CSV utilizados.
- Se decidió reemplazar las variables “aeropuerto_origen” y “aeropuerto_destino” por “ruta_aerea”. El análisis y fundamento de esta decisión se presentan en la sección 2.5.1.2.
- Se eliminó la variable “id”, debido a que actuaba únicamente como identificador del registro y no aportaba valor predictivo.
- Se eliminó la variable “tiempo_estimado_vuelo”. La justificación detallada de esta decisión se desarrolla en la 2.5.1.1.

3.2 Transformación

En secciones previas se hizo referencia a la posible utilidad de crear una variable categórica que represente las rutas aéreas, por lo que se procederá a realizar dicho trabajo.

3.2.1 Variables ruta aérea ordenada y ruta aérea única

La variable “ruta_aerea_ordenada” se construye a partir de todas las duplas observadas de aeropuerto de origen y destino, sin agrupar en una misma categoría dos aeropuertos con distinto sentido. Por ejemplo, EZE-BOG no se considera la misma categoría que BOG-EZE. En cambio, la variable “ruta_aerea_unica” agrupa ambas posibilidades bajo una misma categoría.

Se adelanta el hecho de que se encontró potencial predictivo con estas transformaciones. Posterior al análisis multivariado, se decidirá con cual trabajar en los modelos.

3.2.2 Variable ruta internacional

La variable “ruta_internacional” es una variable binaria que se instancia como “verdadero” en caso de que al menos uno de los aeropuertos de una ruta única sea internacional, entendiéndose así como un aeropuerto cuyo código IATA no pertenezca a uno argentino.

Tipo de ruta	Proporción de demora	Observaciones
Internacional	0.318617	12843
Nacional (Argentina)	0.318034	2157

Tabla 3.1 Proporción de demora por tipo de ruta.

Debido a que en la muestra la frecuencia relativa de la demora no parece variar según el tipo de ruta, se asume que no tiene potencial predictivo y por ende se descarta su uso para los modelos.

3.3 Vista minable

Variable	Tipo	Candidata a eliminar	Candidata a reclasificar
hora_salida_programada	Nominal	Si	Si
dia_semana	Nominal	-	-
distancia_vuelo	Continua	Si	-
condiciones_climaticas	Ordinal	-	Si
congestion_aerea	Ordinal	-	-
tipo_avion	Nominal	-	Si
ocupacion_vuelo	Continua	-	Si
temporada_alta	Binaria	-	-
puerta_embarque	Nominal	Si	-
visibilidad	Continua	Si	-
ruta_aerea_unica	Nominal	-	-
demorado	Binaria	No	No

Tabla 3.2 Vista minable

Como se señaló anteriormente, se eliminaron las variables: aeropuerto_origen, aeropuerto_destino, id_vuelo y tiempo_estimado_vuelo.

Las variables para las cuales se presentó alguna justificación relacionada con una posible exclusión fueron marcadas como candidatas a eliminar. No obstante, la selección final de variables podrá variar según los requerimientos y supuestos de cada modelo, así como también en función de la necesidad de reducir la dimensionalidad del dataset.

De la misma forma, para las variables que se realizó alguna justificación para una reclasificación, fueron marcadas en la cuarta columna. Nuevamente, esto no implica que no se puedan realizar otras reclasificaciones que se crean necesarias para mejorar el rendimiento de los modelos.

Para los casos donde no se mencionó nada, no se marcó ninguna de las dos columnas.

3.4 Configuración de conjuntos de entrenamiento y validación

Se realizó la separación del dataset en conjuntos de entrenamiento y validación utilizando una proporción 70/30, con semilla fijada para garantizar la reproducibilidad de los resultados.

Debido a que las clases de la variable objetivo presentan desbalance (31.85% de vuelos con demora vs 68.15% sin demora), se aplicó estratificación por la variable "demorado" para asegurar que ambas clases se encuentran representadas en ambos datasets.

Adicionalmente, se mantuvo una copia del dataset completo sin particionar para la validación de supuestos estadísticos en LDA y regresión logística, dado que estos modelos requieren verificar condiciones sobre la totalidad de los datos antes de proceder con el ajuste en el conjunto de entrenamiento.

4 Fase de modelado

4.1 Definición del proceso de evaluación de modelos

4.1.1 Priorización de los falsos negativos

Previo a la selección de las métricas para realizar la evaluación de los modelos, resulta fundamental definir qué tipo de error de predicción presenta un costo mayor para el negocio.

Por un lado, el predecir que un vuelo se va a demorar cuando en realidad no lo hace, lo que se denomina falso positivo, incurre en los siguientes costos directos:

- Voucher de comida (25 USD) * Cantidad de pasajeros normales
- Sala VIP (80 USD) * Cantidad de pasajeros VIP⁴

Ambos costos son variables y dependen de la cantidad de pasajeros, que se deriva a partir del porcentaje de ocupación del vuelo y tipo de avión. Tomando como ejemplo un vuelo ficticio que use uno de los tipos de avión más frecuentes, la mediana del porcentaje de ocupación de vuelo y un porcentaje conservador de clientes VIP:

Tipo de avión	Capacidad	Ocupación	Pasajeros a bordo	Pasajeros VIP (10%)	Pasajeros normales
Embraer E190	100 ⁵	73.40%	73	7	66

Tabla 4.1 Características de un vuelo de ejemplo.

⁴ La definición de los segmentos de clientes corresponde a la etapa 2. No obstante, se anticipa que existen clientes que resultan muy valiosos para la empresa y por ende se les da compensaciones mayores.

⁵ La capacidad de pasajeros de este tipo de avión puede variar entre 96 y 114 asientos según la configuración utilizada. La información utilizada sobre la capacidad del tipo de avión fueron extraídos de fuentes externas al dataset original y se encuentran en la bibliografía.

Concepto	Cantidad	Costo unitario (USD)	Costo total (USD)
Vouchers comida	66	25	1650
Sala VIP	7	80	560
Costo total de un falso positivo			2210

Tabla 4.2 Costos del vuelo de ejemplo.

Por otro lado, el predecir que un vuelo no se va a demorar cuando en realidad si lo hace, lo que se denomina falso negativo, incurre en los siguientes costos indirectos asumiendo un criterio pesimista:

- Deserción de un cliente, cuyo costo estimado depende del tipo de cliente.
- Daño a la imagen de la marca, lo que conlleva a menor clientela futura.

Nuevamente, ambos costos son variables y dependen en gran parte la cantidad de pasajeros que tenía el vuelo. Como así también, de la cantidad de clientes VIP que viajaban, puesto que se infiere que el costo estimado de perder a uno de este segmento resulta mucho mayor.

Para aproximar este impacto económico, se usa como referencia el análisis univariado sobre el dataset de clientes de la aerolínea.

Los resultados muestran una elevada heterogeneidad en el valor económico de los pasajeros. El gasto total histórico presenta una mediana de 3551 USD por cliente, mientras que el percentil 90 asciende a 16507 USD y el percentil 99 supera los 70000 USD. Asimismo, los clientes afiliados al programa de millas poseen un gasto promedio de 11359 USD frente a 6343 USD para clientes no afiliados.

De forma similar, los pasajeros cuya clase preferida es primera clase presentan un gasto acumulado promedio superior a 50000 USD, considerablemente mayor al observado en pasajeros de clase económica.

A partir de estos resultados, se utilizará una aproximación simplificada para estimar el impacto económico asociado a la pérdida de clientes producto de una demora no anticipada.

Bajo este criterio, se considerará:

- como costo esperado asociado a un pasajero estándar, el 10% de la mediana del gasto total histórico observada en el dataset (355 USD),
- y como costo esperado asociado a un pasajero VIP, el 10% del percentil 90 del gasto total histórico (1651 USD).

Tomando nuevamente el vuelo de ejemplo anterior (73 pasajeros a bordo y 10% de pasajeros VIP) se obtiene el siguiente resultado:

Concepto	Cantidad	Costo unitario (USD)	Costo total (USD)
Pérdida potencial pasajeros normales	66	355	23430
Pérdida potencial pasajeros VIP	7	1651	11557
Costo total de un falso negativo			34987

Tabla 4.3 Costos estimados de un falso negativo para el vuelo de ejemplo.

Incluso sin tener en cuenta el costo en concepto de daño de la imagen comercial, se puede ver que el costo de un falso negativo supera en gran medida al costo de un falso positivo. Por supuesto, estos valores representan una aproximación y no necesariamente la totalidad de los clientes abandonan la aerolínea luego de una demora no anticipada. No obstante, este resultado nos permite afirmar que desde la perspectiva de negocio, el costo de un falso negativo es mucho mayor al del falso positivo.

Por lo tanto, durante la evaluación de los modelos se deberá priorizar aquellos que mantengan la tasa de falsos negativos lo más baja posible. No obstante, también se debería mantener una tasa razonable de verdaderos negativos para evitar que se produzcan demasiadas falsas alarmas que generen pérdida de credibilidad en el modelo. En este sentido, se considerará adecuado mantener una tasa de verdaderos negativos superior al 60%.

4.1.2 Selección de métricas

Un factor importante en el proceso de selección de métricas para la evaluación de modelos, es el hecho de que la variable objetivo de naturaleza binaria, presenta desbalance dentro de sus dos clases. La clase 1 constituye el 31,85% del dataset mientras que la clase 0 corresponde al 68,15% restante.

En consecuencia, se sabe que el uso de la métrica “accuracy” no sería eficiente puesto que se podría tener un puntaje alto por clasificar con mucha frecuencia la clase mayoritaria, y no estar ni siquiera acertando un 50% a la clase minoritaria.

De todas formas, en la sección anterior se destacó la importancia, desde la perspectiva del negocio, de minimizar la cantidad de vuelos demorados que no son clasificados correctamente por el modelo. Por ende la métrica principal para la evaluación de modelos será que tan baja es la FNR (False Negative Rate) la cual mide la proporción de vuelos efectivamente demorados que fueron clasificados incorrectamente como vuelos sin demora.

Lógicamente, si solo se tuviera en cuenta esa métrica, el mejor modelo sería aquel que clasifique todos los vuelos como demorados. Por ello, como métrica de control se utilizará la TNR (True Negative Rate). Como se mencionó anteriormente, se considerará aceptable mantener esta tasa en torno al 60%.

Es así que el mejor modelo será aquel que minimice la FNR, manteniendo una TNR mayor a 60%.

Finalmente, dado que modelos como LDA y regresión logística generan probabilidades o puntuaciones asociadas a cada registro, y que la TNR y FNR depende del umbral de clasificación seleccionado, resulta conveniente incorporar una métrica independiente del punto de corte. Por ello, se utilizará el área bajo la curva ROC (AUC).

4.2 Evaluación de modelos

4.2.1 KNN

4.2.1.1 Introducción

KNN, K-Nearest Neighbors, es un algoritmo que clasifica un nuevo caso en función de la distancia con sus vecinos más cercanos. Posee un parámetro K que indica la cantidad de vecinos más cercanos considerados para clasificar una nueva observación. Este se obtiene con prueba y error, según los datos del dataset, hasta encontrar el valor de K que ofrece el mejor desempeño según las métricas seleccionadas para el problema.

4.2.1.2 Preparación de Datos

Para aplicar KNN a la vista minable, fue necesario realizar diversas transformaciones sobre los datos para adaptar el dataset a las entradas del algoritmo KNN que tienen que ser numéricas. En primer lugar, se transformó `hora_salida_programada` de un formato tiempo con horas y minutos a un número float. Después se codificaron las variables categóricas utilizando la función `one_hot_encoding`, que cambia las variables categóricas a binarias con la técnica one-hot usando una función de la librería pandas llamada `get_dummies`.

Finalmente, se estandarizaron los datos con `StandardScaler` de la librería Scikit-learn, que transforma las variables numéricas para que tengan media 0 y desviación estándar 1.

4.2.1.3 Desarrollo

Para encontrar el K óptimo del algoritmo, se creó un ciclo iterativo for en Python que entrena y evalúa las métricas de los modelos con diferentes k.

K	FNR	TNR
1	0.6511	0.7144
2	0.6511	0.7144
3	0.7334	0.7998
4	0.7327	0.7998
5	0.7767	0.8435
6	0.7816	0.8497
7	0.8067	0.882
8	0.8137	0.8856
9	0.8416	0.9051
10	0.8479	0.9077

Los modelos con K=1 y K=2 obtuvieron exactamente los mismos resultados sobre el conjunto de prueba. Se seleccionó K=2 debido a que presenta una menor propensión al sobreajuste, ya que la clasificación se realiza considerando dos vecinos en lugar de uno. Además, se observó que, a medida que aumenta el valor de K, mejora la capacidad del modelo para identificar vuelos sin demora (TNR) mientras que empeora la capacidad de detectar los vuelos demorados, lo que se refleja en el aumento de la FNR. Esto es esperable puesto que un K mayor tiende a favorecer a la clase mayoritaria.

4.2.1.4 Evaluación

El mejor modelo con k = 2 obtiene un FNR del 65% y un TNR del 71%, siendo el FNR un valor elevado como para cumplir con el objetivo del estudio, se probaron otras alternativas para mejorar el modelo.

Se analizó la eliminación de ciertas variables de la vista minable para intentar mejorar la precisión de las predicciones del algoritmo. En el caso que más mejoría se vio fue quitando la variable tipo_avion. Esto tiene sentido ya que al ser una variable nominal de 12 categorías (lo que implica la creación de 12 variables dummy), genera un gran aumento en la dimensionalidad lo que reduce la precisión de los algoritmos basados en distancia como K-NN.

Modelo	FNR	TNR
K=2 completo	0.6511	0.7144
K=2 sin tipo_avion	0.61	0.71

Debido a la mejoría identificada, se selecciona el modelo con K = 2 sin tipo_avion como modelo de K-NN final, pendiente a comparar contra el mejor modelo de cada algoritmo.

Matriz de confusión




Figura 4.1 Matriz de confusión del modelo seleccionado.

4.2.2 Árboles de decisión (Modeler)

4.2.2.1 Introducción

Para el estudio del modelo de árbol de decisión en SPSS Modeler, primero se evaluaron los 6 tipos de modelos de árboles que incluye el software y se decidió utilizar el árbol de CHAID, que tuvo mejor rendimiento inicial. Luego, se tuvo más éxito en optimizar el modelo modificando sus parámetros que transformando las variables.

4.2.2.2 Elección del algoritmo

En la primera etapa, para elegir qué modelo usar, se entrenaron contra la misma vista minable definida los 6 algoritmos de árbol disponibles en SPSS Modeler:

Árboles Aleatorios, AS de árbol, C&R, C5.0, CHAID y Quest. Se busca encontrar el algoritmo que mejor se ajusta con los parámetros por defecto para luego continuar con la optimización del modelo.

Se utilizaron las curvas de Ganancia y de ROC para comparar los modelos, y en ambas se nota que el mejor algoritmo de los seis es el árbol CHAID.




Figura 4.2 Curvas ROC y de Ganancia de los diferentes árboles.

La tabla de valores AUC muestra que R3 (CHAID) es buen candidato para empezar:

Modelo	AUC
Random	0,610
AS	0,658
C&R	0,580
C5.0	0,580
CHAID	0,678
Quest	0,579

		\$R3-demora	
demora		1	0
1	Recuento	323	1110
	% de filas	22.54%	77.46%
0	Recuento	214	2853
	% de filas	6.98%	93.02%

Tabla 4.1 AUC de los árboles y matriz de confusión del árbol CHAID.

Sin embargo, la matriz de confusión indica que este modelo inicial no es útil: a simple vista se ve que el porcentaje de TP y TN está muy desbalanceado.

4.2.2.3 Preparación de Datos

Una vez elegido el algoritmo, se procede a una etapa de transformación de variables para optimizar el modelo. Se realizaron las siguientes transformaciones:

- Reclassificaron de la variable Temporada_alta (nominal) como ordinal numérica.
- Creación de la variable periodo_dia (nominal) a partir de hora_salida_programada (continua) según los siguientes rangos:
 - “Mañana” para el rango [6hs–14hs)
 - “Tarde” para el rango [14hs–22hs)
 - “Noche” para el rango [22hs–6hs)

Luego de estas transformaciones, se mantiene el mismo performance: Este modelo tiene una tasa de falsos negativos del 77%, hará predicciones casi completamente erróneas.

		\$R3-demora	
demora		1	0
1	Recuento	323	1110
	% de filas	22.54%	77.46%
0	Recuento	214	2853
	% de filas	6.98%	93.02%

Tabla 4.2 Matriz de confusión del árbol CHAID luego de las transformaciones.

4.2.2.4 Evaluación


Una vez obtenido el modelo con las variables adecuadas, evaluamos el modelo con los siguientes parámetros:

- Matriz de costos: (FN, FP) = (5, 2). Es más costoso predecir mal una demora que una no-demora.
- Altura máxima: Se evalúan modelos variando la altura máxima de 2 a 6.

Altura Máx.	TNR	FNR	AUC
2	0,643	0,389	0,668
3	0,586	0,324	0,680
4	0,577	0,318	0,681
5	0,577	0,318	0,679
6	0,577	0,318	0,679

Tabla 4.3 TNR, FNR, y AUC sobre las diferentes profundidades.

Se observa una gran mejora general en el FNR, producto de la aplicación de la matriz de costos. Y entre las alturas, una ligera ventaja en el modelo de altura 4. Esta es la configuración óptima para el modelo. A continuación se hace un análisis del modelo resultante:



		\$R2-demora	
demora		1	0
1	Recuento	977	465
	% de filas	68.18%	31.82%
0	Recuento	1296	1771
	% de filas	42.26%	57.74%

Figura 4.3 y Tabla 4.4 Curva ROC y Matriz de confusión del árbol seleccionado.

Se observa que el modelo tiene una baja tasa de falsos negativos y una tasa no aceptable de verdaderos negativos puesto que la TNR no llega al 60%.

Conjunto de entrenamiento			
		Predicción	
		1	0
1	Recuento	2290	1055
	% de filas	48.46%	31.54%
0	Recuento	2971	4184
	% de filas	41.52%	58.48%

Conjunto de test			
		Predicción	
		1	0
1	Recuento	977	456
	% de filas	68.18%	31.82%
0	Recuento	1296	1771
	% de filas	42.26%	57.74%

Tabla 4.5 Matrices de confusión de entrenamiento y test para el modelo ajustado

- Entrenamiento:
 - True Negative Rate (TNR): 0.585
 - False Negative Rate (TNR): 0.315
- Test:
 - True Negative Rate (TNR): 0.577
 - False Negative Rate (TNR): 0.318

También podemos corroborar que el modelo no está sobreajustado, ya que las matrices de confusión tienen proporciones similares tanto en train como en test. Las métricas obtenidas finalmente son:

- TNR: 57.7%
- FNR: 31.8%
- AUC: 68.1%

Estas indican una baja tasa de falsos negativos. Sin embargo, como el modelo no alcanza el umbral aceptable de verdaderos negativos (60%), no cumple el estándar del estudio. Esto nos indica que este modelo no será de utilidad como predictor.

4.2.3 Árboles de decisión (Python)

4.2.3.1 Introducción

Para el estudio del modelo de árboles de decisión en Python, se implementó un clasificador utilizando la librería Scikit-learn, el cual utiliza por defecto el índice de Gini como criterio de impureza.

Además, debido al desbalance natural en los datos (mayor cantidad de vuelos sin demora que demorados), y la necesidad de detectar de mejor manera aquellos vuelos que si se demoran, se utilizaron parámetros que explicaremos posteriormente a fin de priorizar estas demoras.

4.2.3.2 Preparación de Datos

En una etapa inicial, antes del proceso de transformación de variables, se llevó a cabo una ejecución preliminar del algoritmo. Esta se realizó utilizando la vista minable previamente definida, con el objetivo de analizar el comportamiento base del modelo. Para este abordaje inicial, se configuró un árbol con una profundidad de 5 niveles.

Los resultados de las métricas de desempeño obtenidos en esta primera evaluación se detallan a continuación:

Métrica	Valor
TNR	0.4959
FNR	0.2966

Métricas de desempeño sobre el conjunto de prueba para el árbol de decisión con profundidad máxima de 5

A partir de este modelo inicial, se determinó que el algoritmo presenta un rendimiento no satisfactorio de verdaderos negativos (49.59% de TNR), no cumplimentando nuestro 60% de mínimo, pero a su vez tiene un bastante buen porcentaje de falsos negativos (29.66% de FNR), lo cual nos ofrece un buen ratio de no predecir erróneamente vuelos no demorados cuando sí lo están.

Con el objetivo de optimizar el modelo, se procedió a una fase de transformación de las variables. Las modificaciones realizadas en el conjunto de datos que impactaron positivamente en el desempeño del árbol fueron:

- Exclusión de las variables “tipo_avion”, “puerta_embarque” y “dia_semana” dado que, al probar diferentes iteraciones del modelo, se detectó que quitando estas se alcanzaban los mejores valores en las métricas.

- Aplicación de *one-hot encoding* para convertir los datos categóricos en columnas numéricas binarias.
- Creación de la variable “periodo_dia” mediante la recodificación de “hora_salida_estimada” en los siguientes rangos:
 - Mañana: 6:00 a 14:00 horas.
 - Tarde: 14:00 a 22:00 horas.
 - Noche: 22:00 a 6:00 horas.

4.2.3.3 Evaluación

Luego de realizar todas estas transformaciones en el dataset, se realizó una serie de iteraciones con diferentes profundidades de árboles a fin de encontrar el mejor árbol.

Además, se definieron una serie de parámetros del árbol que permiten ajustar el mismo para nuestro caso de estudio:

- 'tree_class_weight': {0:1,1:3} (Es más costoso fallar en una demora que en una no demora)
- 'treecriterion': 'gini'
- 'treemin_samples_leaf': 25,
- 'tree_min_samples_split': 20

Los resultados más relevantes fueron los siguientes:

Max Depth	Dataset	TNR	FNR
2	Train	0.3993	0.2099
	Test	0.4144	0.2094
3	Train	0.2699	0.1073
	Test	0.2798	0.1103
4	Train	0.3382	0.1543
	Test	0.3469	0.1563
5	Train	0.4690	0.2290
	Test	0.4630	0.2366
6	Train	0.6197	0.3220
	Test	0.6094	0.3587
7	Train	0.4787	0.2081
	Test	0.4643	0.2442

8	Train	0.5899	0.2777
	Test	0.5683	0.3433

Tabla 4.6 TNR y FNR sobre las diferentes profundidades.

Con las tablas anteriores, se determinó que la configuración óptima corresponde a un árbol con profundidad de 6. Estos resultados representan los árboles que poseen un mejor rendimiento, dado que incrementos adicionales en la profundidad provocan una degradación importante sobre las métricas contempladas.

Complementariamente, el análisis de las curvas ROC permitió identificar que el modelo de profundidad 6 posee un valor de $AUC = 0.67$.




Figura 4.4 Curva ROC del modelo.

Ante esto, se procedió a realizar una evaluación final del modelo con los parámetros que fueron dados anteriormente que brindaron la profundidad óptima.

La aplicación de estos parámetros, junto a una profundidad de 6, arrojó los resultados que se presentan a continuación:




Figura 4.5 Matrices de confusión de entrenamiento/test del modelo ajustado.

- Entrenamiento:
 - True Negative Rate (TNR): 0.6197
 - False Negative Rate (FNR): 0.3220
- Test:
 - True Negative Rate (TNR): 0.6094
 - False Negative Rate (FNR): 0.3587

Aquí podemos ver que el modelo no se encuentra sobreajustado, gracias a la comparación de las matrices de confusión, las cuales tienen un comportamiento similar. Esto aunado con las métricas utilizadas a lo largo de este estudio, las cuales son:

- TNR = 60.94%
- FNR = 35.87%
- AUC = 0.67

Esto nos indica que hay una baja tasa de falsos negativos, con un umbral aceptable de casi el 61% de verdaderos negativos, cumpliendo los estándares generales de este análisis.

4.2.4 Análisis Discriminante

4.2.4.1 Introducción

El Análisis Discriminante (LDA) es una técnica estadística multivariante y de clasificación supervisada que sirve para identificar qué variables o características permiten diferenciar a dos o más grupos sujetos.

Su objetivo principal es encontrar la combinación lineal de las variables independientes que mejor separe o discrimine a dichos grupos. Una vez que se halla esta combinación matemática (llamada función discriminante), su propósito final es utilizarla para predecir y clasificar nuevos casos desconocidos, asignados al grupo correcto con la mayor precisión posible.

4.2.4.1 Preparación de Datos

En el contexto de este trabajo, el modelo de Análisis Discriminante se aplica para diferenciar los vuelos que sufrieron una demora de aquellos que operaron a tiempo, determinando qué variables tienen mayor capacidad para clasificar ambas categorías.

El entrenamiento del modelo se llevó a cabo utilizando el conjunto de datos `vuelos_original_train.csv`. La partición de la muestra en entrenamiento y prueba se realizó en una etapa de preprocesamiento previa a su importación en SPSS Statistics, con el fin de agilizar y estandarizar el flujo de trabajo.

Dado que el modelo LDA admite únicamente el uso de variables independientes numéricas, se procedió a realizar un preprocesamiento del conjunto de datos. En primer lugar, se aplicó una codificación numérica discreta a métricas de baja cardinalidad que demostraron tener capacidad predictiva sobre la variable objetivo, tales como `condiciones_climaticas` y `congestion_aerea`.

Por otro lado, se determinó la exclusión de las variables de día semana, tipo de avión, puerta de embarque y hora de salida programada debido a su alta cardinalidad, lo que generaría un problema de dimensionalidad excesiva. Además, durante la etapa del EDA, se corroboró que ninguna de las variables excluidas influye de manera significativa en la variable objetivo.

Para el caso de la variable de condiciones climáticas va a ser recodificada de la siguiente manera en la variable “condiciones_climaticas_recod”:

Valor Original	Valor Nuevo
Despejado	1
Nublado	2
Lluvia	3
Niebla	4
Tormenta	5

Para el caso de la variable congestión aérea va a ser recodificada de la siguiente manera en la variable “congestion_aerea_recod”:

Valor Original	Valor Nuevo
Baja	1
Media	2
Alta	3

4.2.4.2 Entrenamiento

Por consiguiente, tras aplicar las transformaciones detalladas, el primer modelo de Análisis Discriminante Lineal (LDA) estará conformado por las siguientes variables:

- distancia de vuelo
- ocupación de vuelo
- visibilidad
- temporada alta
- congestión aérea (recodificada)
- condiciones climáticas (recodificada)
- tiempo estimado de vuelo

Una vez finalizada la etapa de transformación de los datos, se debe comprobar el cumplimiento de los tres supuestos estadísticos fundamentales para la validez del Análisis Discriminante Lineal. Estos supuestos son:

- Distribución normal de las variables.
- No multicolinealidad.

- Matrices de covarianzas-varianzas iguales.
- Supuesto de diferencia significativa entre medias

4.2.4.3 Supuesto de Normalidad

En esta sección se evalúa si las variables independientes continuas se ajustan a una distribución normal. Para ello, se plantea el siguiente contraste de hipótesis:

- H_0 (Hipótesis nula): La variable analizada proviene de una población con distribución normal.
- H_1 (Hipótesis alternativa): La variable analizada difiere significativamente de una distribución normal.

Dado que el tamaño de la muestra supera las 50 observaciones ($n > 50$), la comprobación analítica de este supuesto se llevó a cabo mediante la prueba de bondad de ajuste de Kolmogorov-Smirnov. Los resultados obtenidos a través del software SPSS Statistics se detallan en la siguiente tabla:

		Kolmogorov-Smirnov ^a		
	demora	Estadístico	gl	Sig.
visibilidad	0	,060	9831	,000
	1	,087	4607	,000
temporada_alta	0	,431	9831	,000
	1	,379	4607	,000
congestion_aerea_recod	0	,288	9831	,000
	1	,204	4607	,000
condiciones_climaticas_recod	0	,276	9831	,000
	1	,218	4607	,000
ocupacion_vuelo	0	,056	9831	,000
	1	,059	4607	,000
distancia_vuelo	0	,231	9831	,000
	1	,225	4607	,000
tiempo_estimado_vuelo	0	,215	9831	,000
	1	,207	4607	,000

Tabla 4.7 Prueba no normalidad de Kolmogorov-Smirnov.

Como resultado, se analiza el valor del “p - value”(columna Sig. en la tabla) que indica si los datos se desvían significativamente de la normalidad. Si este valor es mayor a nuestro nivel de significancia establecido (0,05), no se rechaza la hipótesis

nula (H_0) y se asume normalidad. De lo contrario, existe evidencia estadística suficiente para descartarla y aceptar la hipótesis alternativa (H_1): los datos no siguen una distribución normal.

Bajo este criterio, los resultados indican que ninguna de las variables analizadas sigue una distribución normal en los grupos ($p < 0,001$ en todos los casos).

Sin embargo, la prueba de Kolmogorov-Smirnov es extremadamente sensible ante muestras de gran volumen (en este caso, una muestra de 15.000 datos), tendiendo a rechazar la normalidad ante variaciones mínimas que no tienen un impacto real en la práctica.

Además, se sabe que las variables como las condiciones climáticas o la temporada alta, son de tipo categóricas u ordinales. Por lo tanto, por definición matemática estas variables no pueden ajustarse a una distribución normal, contribuyendo al rechazo generalizado de la hipótesis nula. Se decidió dejarlas aun sabiendo la naturaleza de las variables en un primer modelo debido a que estas variables tienen una correlación alta con la variable objetivo. Luego, se probará hacer el modelo limitándose a solo introducir variables numéricas continuas.

Como se sabe que el modelo LDA es lo suficientemente robusto para soportar estas desviaciones (sobre todo al contar con miles de registros), se avanza de todos modos con el análisis.

4.2.4.4 Supuesto de No multicolinealidad

Para analizar el supuesto de No multicolinealidad nos basamos en el índice de condición del diagnóstico de colinealidad y el Factor de Inflación de la Varianza (FIV) junto con la tolerancia proporcionado por el SPSS Statistics. Para eso se plantea la siguiente hipótesis:

- H_0 : no existe colinealidad severa entre las variables independientes.
- H_1 : hay colinealidad severa entre algunas variables independientes.

Si el valor del índice supera el valor de 30, se tiene una multicolinealidad y se rechazará la hipótesis nula. Caso contrario, no se rechaza la hipótesis nula y se corrobora que no existe colinealidad severa entre las variables del modelo.

Los resultados obtenidos se presentan en la siguiente tabla:

Modelo	Dimensión	Autovalor	Índice de condición	(Constante)	Proporciones de varianza							
					distancia_vuelo	ocupacion_vuelo	visibilidad	temporada_alta	congestion_area_recod	condiciones_climaticas_recod	tempo_estimado_vuelo	
1	1	5,847	1,000	,00	,00	,00	,00	,01	,00	,00	,00	
	2	,940	2,494	,00	,00	,00	,00	,06	,01	,01	,00	
	3	,589	3,149	,00	,00	,00	,01	,02	,01	,01	,00	
	4	,389	3,876	,00	,00	,00	,21	,00	,00	,27	,00	
	5	,141	6,442	,00	,00	,00	,20	,00	,74	,18	,00	
	6	,075	8,842	,02	,00	,34	,41	,00	,15	,38	,00	
	7	,018	17,924	,69	,00	,66	,16	,01	,10	,16	,00	
	8	,001	91,994	,29	1,00	,00	,00	,00	,00	,00	1,00	

a. Variable dependiente: demora

Tabla 4.8 Diagnóstico de colinealidad.

El análisis arrojó un índice de condición de 91,994. Al ser un valor superior al umbral de 30, se rechaza la hipótesis nula, confirmando la existencia de multicolinealidad severa en el modelo.

Para identificar las variables afectadas, se analizó los valores del Factor de Inflación de la Varianza (FIV). Como era de esperarse por lo visto en la etapa previa, se confirma una alta colinealidad entre la distancia de vuelo y el tiempo estimado de vuelo⁶. Adicionalmente, se detectó una colinealidad moderada entre visibilidad y las condiciones climáticas.

A pesar de no cumplir con este supuesto, y para mantener un orden procedimental, se decidió avanzar con esta primera versión base del modelo. En instancias posteriores, se realizan nuevas iteraciones excluyendo estas variables conflictivas para comparar resultados y determinar cuál es la configuración óptima.

4.2.4.5 Supuesto de matrices de varianza y covarianza iguales

Para evaluar este supuesto, se planteó el siguiente contraste de hipótesis:

- H_0 (Hipótesis nula): Las matrices de varianzas y covarianzas poblacionales son iguales en todos los grupos.
- H_1 (Hipótesis alternativa): Las matrices de varianzas y covarianzas poblacionales difieren entre los grupos.

La validación de esta premisa se llevó a cabo mediante la prueba estadística M de Box, procesada en SPSS Statistics. El criterio de decisión se basa en analizar el nivel de significación asintótica (p-valor, referenciado como "Sig." en los resultados de la herramienta) para determinar el rechazo o no de la hipótesis nula.

A continuación se presenta la tabla con el valor de M de Box:

Resultados de prueba		
M de Box		420,692
F	Aprox.	15,012
	gl1	28
	gl2	150333549,3
	Sig.	,000
Prueba la hipótesis nula de las matrices de covarianzas de población iguales.		

Tabla 4.9 Resultados de M de Box.

⁶ Si bien esta variable fue excluida de la vista minable, se la dejó para ilustrar la validación del supuesto de no multicolinealidad.

Los resultados de la prueba M de Box arrojaron un nivel de significación asintótica de 0,000. Al ser estrictamente menor que el umbral de 0,05, se rechaza la hipótesis nula, confirmando empíricamente que las matrices de varianzas y covarianzas difieren significativamente entre los grupos.

A modo de balance, el análisis exploratorio de los datos demuestra que se vulneran los tres supuestos paramétricos fundamentales del LDA. A pesar de estas restricciones teóricas, se resolvió continuar con la ejecución del algoritmo para utilizarlo como modelo de referencia (baseline). Somos conscientes de que su ajuste general puede verse comprometido por la naturaleza de los datos; por ende, su desempeño frente a los demás modelos se evaluará prestando especial atención a métricas específicas como el Recall (exhaustividad).

4.2.4.6 Supuesto de diferencia significativa entre medias

Para evaluar este supuesto, se planteó el siguiente contraste de hipótesis mediante el estadístico Lambda de Wilks:

- H_0 (Hipótesis nula): Los grupos poseen el mismo vector de medias poblacionales para las variables explicativas.
- H_1 (Hipótesis alternativa): Al menos uno de los grupos presenta diferencias en el vector de medias poblacionales respecto de los demás grupos.

La validación de este supuesto se realizó mediante el estadístico Lambda de Wilks. El criterio de decisión consiste en analizar el nivel de significación asintótica (p-valor, identificado como "Sig." en los resultados obtenidos) para determinar el rechazo o no de la hipótesis nula de igualdad de medias multivariadas entre los grupos.

A continuación, se presenta la tabla correspondiente al estadístico Lambda de Wilks:

Lambda de Wilks				
Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	,914	911,387	7	,000

Tabla 4.10 Estadístico Lambda de Wilks.

Como se puede observar en la tabla anterior, el valor de la significancia asociado al estadístico Lambda de Wilks es menor a 0,05. Por lo tanto, se rechaza la hipótesis nula de igualdad de medias entre los grupos.

Esto indica que existen diferencias significativas entre los vectores de medias de las variables.

4.2.4.7 Evaluación

En esta sección se llevará a cabo una evaluación exhaustiva de los modelos desarrollados a lo largo del estudio. Para ello, se contrastará el rendimiento de cada iteración, basando la comparación en métricas de clasificación clave.

El objetivo final es determinar qué configuración presenta la mayor robustez y capacidad predictiva para identificar correctamente los vuelos demorados, dadas las limitaciones encontradas en los supuestos de los datos.

La evaluación de los tres modelos se llevará a cabo de forma simultánea. Este enfoque comparativo tiene como propósito facilitar la comprensión de los resultados y permitir un contraste visual mucho más claro de las características y el rendimiento de cada iteración.

Siendo las variables utilizadas para cada modelo:

Modelo 1	Modelo 2	Modelo 3
condiciones_climaticas_recod	condiciones_climaticas_recod	condiciones_climaticas_recod
congestion_aerea_recod	congestion_aerea_recod	congestion_aerea_recod
temporada_alta	temporada_alta	temporada_alta
visibilidad	visibilidad	-
distancia_vuelo	-	-
tiempo_estimado_vuelo	-	-

En el Modelo 2, se procedió a excluir las variables de distancia de vuelo y el tiempo estimado de vuelo con el objetivo primordial de erradicar la multicolinealidad severa detectada en la iteración inicial. Esta intervención fue exitosa, dado que el índice de condición se redujo significativamente a 10,199, permitiendo así dar por cumplido el supuesto de ausencia de multicolinealidad.

Por su parte, en la configuración del Modelo 3 se optó por omitir adicionalmente la variable visibilidad. El motivo radica en la colinealidad moderada que esta presentaba frente a condiciones_climaticas_recod. Se decidió conservar esta última dado que consolida una mayor cantidad de información explicativa, volviendo a la visibilidad un dato redundante para el análisis (tal como se detalla en la sección 4.3).

A continuación se presenta las tablas de Matriz de Estructura de los tres modelos:

Matriz de estructuras		Matriz de estructuras		Matriz de estructuras	
	Función 1		Función 1		Función 1
condiciones_climaticas_r	,706	condiciones_climaticas_r	,708	condiciones_climaticas_r	,709
ecod		ecod		ecod	
congestion_aerea_recod	,573	congestion_aerea_recod	,574	congestion_aerea_recod	,576
visibilidad	-,413	visibilidad	-,413	visibilidad	
temporada_alta	,346	temporada_alta	,347	temporada_alta	,348
ocupacion_vuelo	,039	ocupacion_vuelo	,039		
distancia_vuelo	,016				
tiempo_estimado_vuelo	,015				

Tabla 4.11 Matrices de estructura.

El análisis de las matrices de estructura confirma una gran estabilidad entre los modelos, con variaciones de coeficientes inferiores a 0,003 puntos. En todos los casos, las condiciones climáticas ($r \approx 0,70$) y la congestión aérea ($r \approx 0,57$) se consolidan como las variables con mayor poder discriminante.

Por el contrario, la casi nula correlación de la ocupación de vuelo, distancia de vuelo y el tiempo estimado de vuelo en el Modelo 1 ($r < 0,04$) justifica plenamente su exclusión progresiva.

Por otro lado, la variable visibilidad ($r = -0,413$) aportó información coherente pero redundante frente al clima, motivando su descarte en el Modelo 3.

Los resultados de clasificación de los tres modelos discriminantes se presentan en las tablas de confusión correspondientes, evaluadas sobre los conjuntos de entrenamiento, validación cruzada y prueba.

A continuación se presentan los valores de las métricas TNR, FNR y AUC de cada modelo:

Métrica	Modelo 1	Modelo 2	Modelo 3
Variables	7	5	3
TNR	92,5%	92,7%	93,3%
FNR	78,6%	79,3%	79,9%
AUC	0,679	0,680	0,680

Tabla 4.12 Tabla de matrices de evaluación

Analizando las métricas de los tres modelos, se ve un alto porcentaje de tasa de verdaderos negativos (TNR) superando el 90% en todos los modelos. Esto indica que se predicen de una buena manera los vuelos sin demora.

Sin embargo, en los tres modelos el FNR es muy elevado, que va desde el 78,8% a 79,9%. Esto indica que prácticamente el 80% de los vuelos que realmente se demoran son clasificados de manera incorrecta como no demorados. Esto es crítico para la aerolínea, porque generaría una pérdida monetaria elevada por estos casos. Una posible causa de estos altos valores del FNR es el desbalance de clases que presenta el dataset, donde un 68% de los casos corresponde a vuelos sin demora. En consecuencia, analizando esta métrica ya es suficiente para determinar que ninguno de los tres modelos cumplen satisfactoriamente con el objetivo de la aerolínea, que es identificar los vuelos con demora.

Con respecto al área bajo la curva (AUC), los tres modelos tienen valores prácticamente idénticos, con un umbral que no supera el umbral de discriminación aceptable (0,700), lo que refuerza las limitaciones de los modelos para poder distinguir entre las dos clases.

Considerando el conjunto de las tres métricas, el modelo 3 es el más equilibrado, ya que tiene un mayor TNR y un AUC equivalente al de los otros dos modelos. Además, este modelo solo cuenta con 3 variables, lo que significa que las variables del modelo son estadísticamente más significativas y libres de multicolinealidad.

A continuación se presenta la matriz de confusión del modelo más óptimo (Modelo 3) de los tres que entrenamos:

Resultados de clasificación^{a,b,d}

			Pertenencia a grupos pronosticada			
			demora	0	1	Total
Casos seleccionados	Original	Recuento	0	6438	443	6881
			1	2549	676	3225
		%	0	93,6	6,4	100,0
			1	79,0	21,0	100,0
	Validación cruzada ^c	Recuento	0	6438	443	6881
			1	2549	676	3225
		%	0	93,6	6,4	100,0
			1	79,0	21,0	100,0
Casos no seleccionados	Original	Recuento	0	2752	198	2950
			1	1104	278	1382
		%	0	93,3	6,7	100,0
			1	79,9	20,1	100,0

Tabla 4.13 Matriz de confusión Modelo 3

Al observar los resultados, se evidencia que las tasas de clasificación correcta en los datos de entrenamiento y prueba son prácticamente idénticas. Por lo tanto, queda comprobado empíricamente que el modelo es estable y no sufre de sobreajuste (overfitting).

4.2.4.8 Ajuste del modelo seleccionado

Con el objetivo de mejorar el modelo LDA seleccionado, se va a utilizar la curva ROC para encontrar otro punto de corte que mejore el FNR sin disminuir de manera considerable el TNR.

A continuación se muestra el gráfico de la curva ROC proporcionado por el SPSS:



Figura 4.6 Curva ROC del modelo.

Como se dijo en la sección anterior, el área bajo la curva (AUC) obtuvo un valor de 0,680, tal como se observa en el gráfico. Este resultado indica que el modelo posee una capacidad aceptable para diferenciar entre los vuelos que se demoran y los que no.

Con el objetivo de identificar el punto de corte más adecuado para el modelo, se analizó las coordenadas de la curva ROC. Para esto, se buscó el valor en el cual la diferencia entre la sensibilidad y la especificidad fuera la más cercana a cero posible, ya que en este punto se logra el equilibrio entre ambas métricas.

Una vez hecho el análisis de coordenadas, se determinó que el punto óptimo de corte es 0,308.

A diferencia de la regresión logística, el análisis discriminante de SPSS no tiene opción para cambiar el punto de corte. Es por eso que se hará de manera manual usando las probabilidades guardadas.

Tabla cruzada demora*clase_optima_m3

			clase_optima_m3		Total
			,00	1,00	
demora	0	Recuento	1905	1045	2950
		% dentro de demora	64,6%	35,4%	100,0%
	1	Recuento	517	865	1382
		% dentro de demora	37,4%	62,6%	100,0%
Total		Recuento	2422	1910	4332
		% dentro de demora	55,9%	44,1%	100,0%

Tabla 4.14: Matriz confusión modelo ajustado

A continuación se presenta la matriz de confusión con el punto de corte en 0,308. Con esta tabla del modelo con el de corte ajustado, se procedió a calcular los valores de las métricas utilizadas para evaluar si se obtuvo alguna mejora con el modelo sin ajustar (punto de corte igual a 0,500). A continuación se muestra una tabla comparativa de dichos modelos con sus valores de métricas.

Métrica	Punto de corte 0,500	Punto de corte 0,308
TPR	20,1%	62,6%
TNR	93,3%	64,6%
FNR	79,9%	37,4%

Tabla 4.15: Tabla comparativa entre ajustes

Viendo los porcentajes de las métricas, podemos concluir que variando el punto de corte al óptimo proporcionado por la curva ROC, la capacidad del modelo para detectar vuelos demorados reales (TPR) se triplicó, reduciendo considerablemente la cantidad de vuelos con demora no detectados, que pasó de un 79,9% a un 37,4%.

Sin embargo, este ajuste implicó que disminuyera la cantidad de vuelos sin demora detectados por el modelo, que bajó de 93,3% a un 64,6%.

Por otro lado, el punto de corte seleccionado permitió minimizar la FNR manteniendo la TNR por encima del 60%, logrando un equilibrio adecuado entre la detección de vuelos demorados y la cantidad de falsas alarmas generadas.

4.2.4.9 Funcion Discriminante obtenida

El modelo LDA óptimo genera una función discriminante lineal de forma:

$$LD = -2,997 + 0,782 \cdot X_1 + 0,602 \cdot X_2 + 0,819 \cdot X_3$$

Siendo:

X_1 : Temporada alta

X_2 : Condiciones climáticas

X_3 : Congestión aérea

4.2.5 Regresión Logística

4.2.5.1 Preparación de los datos

Se realizaron varias transformaciones a la vista minable para aplicar regresión logística al dataset, en primer lugar se recodifico ruta_aerea_unica a una nueva variable llamada "tipo_ruta", con valores posibles de "Nacional" (Vuelos dentro de Argentina) e "Internacional" (Vuelos con origen o destino fuera de Argentina) a fin de facilitar el manejo de los datos en los pasos siguientes. Después, se transformó a todas las variables categóricas utilizando one hot encoding para transformarlas en variables binarias que puede utilizar el algoritmo de regresión logística.

Se incluyeron dentro del modelo como variable dependiente a demora, siendo 0 que no hay demora del vuelo y 1 que el vuelo va a tener demora, y las variables independientes son todas las variables restantes.

Se deben realizar varias pruebas para determinar si la vista minable puede utilizar a la regresión logística como algoritmo de clasificación, además de verificar si se cumplen los supuestos del modelo, y en algunos casos en los cuales estos supuestos no se cumplen, se pueden realizar transformaciones sobre la vista minable para adaptarse al algoritmo.

4.2.5.1 Prueba conjunta

Se parte de la hipótesis nula:

H₀ (hipótesis nula): Para todo coeficiente β de la ecuación tiene que ser cero y ninguna explica a la variable dependiente

H₁ (hipótesis alternativa): Existe al menos un coeficiente β que sea distinto de 0, por lo tanto hay por lo menos alguna variable explicativa.

Para rechazar la hipótesis nula se observa el p-valor del modelo que se encuentra en la tabla de pruebas omnibus de coeficientes del modelo, este valor se encuentra

en el campo que está en la fila modelo y la columna sig, como indica un valor menor a 0.05 por lo tanto esto permite sacar la conclusión de que hay variables explicativas dentro del modelo.

Omnibus Tests of Model Coefficients

		Chi-square	df	Sig.
Step 1	Step	1438.590	10	.000
	Block	1438.590	10	.000
	Model	1438.590	10	.000

Tabla 4.16 Matriz de prueba Ómnibus.

4.2.5.3 Significancia de coeficientes

Se procede a determinar cuáles variables independientes tienen una influencia estadísticamente significativa sobre la probabilidad de demora. Para esto, primero se analiza la tabla “Variables en la ecuación” generada por Statistics, observando el valor que tienen en la columna Significancia (Sig) de cada coeficiente.

H₀ (hipótesis nula): $\beta = 0$ → la variable no tiene efecto sobre la variable dependiente.

H₁ (hipótesis alternativa): $\beta \neq 0$ → la variable tiene efecto sobre la variable dependiente.

Si $\beta_i > 0$ entonces un aumento en X_i aumenta la probabilidad de $Y=1$

Si $\beta_i < 0$ entonces un aumento en X_i disminuye la probabilidad de $Y=1$

Se utiliza un nivel de significancia del 5% ($\alpha = 0,05$), por lo tanto:

Si sig. < 0,05, se rechaza la hipótesis nula → la variable es significativa.

Si sig. $\geq 0,05$, no se puede rechazar H₀ → la variable no aporta al modelo.

En la primer corrida realizada del modelo, con todas las variables independientes incluidas, se obtuvo como resultado la siguiente tabla “Variables en la ecuación”:

		Variables in the Equation					
		B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a	distancia_vuelo	.000	.000	1.466	1	.226	1.000
	ocupacion_vuelo	.002	.001	2.712	1	.100	1.002
	temporada_alta	.469	.038	152.934	1	.000	1.599
	visibilidad	.001	.003	.108	1	.743	1.001
	periodo_dia_Manana	-.034	.040	.716	1	.397	.966
	periodo_dia_Noche	-.073	.061	1.471	1	.225	.929
	dia_semana_Domingo	-.059	.065	.805	1	.370	.943
	dia_semana_Jueves	-.259	.068	14.363	1	.000	.772
	dia_semana_Lunes	-.181	.068	6.956	1	.008	.835
	dia_semana_Martes	-.172	.069	6.261	1	.012	.842
	dia_semana_Miercoles	-.207	.067	9.553	1	.002	.813
	dia_semana_Sabado	-.119	.066	3.288	1	.070	.887
	condiciones_climaticas_Despejado	-1.612	.080	405.637	1	.000	.199
	condiciones_climaticas_Lluvia	-1.129	.087	167.344	1	.000	.323
	condiciones_climaticas_Niebla	-.691	.089	60.762	1	.000	.501
	condiciones_climaticas_Nublado	-1.700	.084	404.913	1	.000	.183
	congestion_aerea_Alta	.641	.048	181.812	1	.000	1.899
	congestion_aerea_Baja	-.476	.043	125.084	1	.000	.621
	tipo_avion_ATR72	-.069	.085	.664	1	.415	.933
	tipo_avion_AirbusA320	-.109	.086	1.613	1	.204	.896
	tipo_avion_AirbusA320neo	-.040	.087	.206	1	.650	.961
	tipo_avion_AirbusA330	.281	.123	5.235	1	.022	1.325
	tipo_avion_AirbusA350	.098	.124	.621	1	.431	1.103
	tipo_avion_Boeing737	-.018	.085	.045	1	.832	.982
	tipo_avion_Boeing737MAX	.007	.088	.006	1	.940	1.007
	tipo_avion_Boeing757	.008	.087	.008	1	.930	1.008
	tipo_avion_Boeing777	.047	.123	.148	1	.700	1.048
	tipo_avion_Boeing787	.095	.127	.555	1	.456	1.099
	tipo_avion_EmbraerE190	-.119	.086	1.934	1	.164	.888
	tipo_ruta_Internacional	.038	.054	.483	1	.487	1.038
	Constant	.470	.139	11.349	1	.001	1.600

Tabla 4.17 Tabla de variables contempladas en el modelo.

Utilizando la tabla para detectar y quedarnos con las variables que explican a la variable dependiente, y en varias iteraciones de la tabla se fueron eliminando las otras. A continuacion estan las eliminadas y el orden en el que fueron eliminadas:

Sacamos tipo_avion_Boeing737MAX

tipo_avion_Boeing737MAX	.007	.088	.006	1	.940	1.007
-------------------------	------	------	------	---	------	-------

Sacamos tipo_avion_Boeing757

tipo_avion_Boeing757	.001	.088	.000	1	.991	1.001
----------------------	------	------	------	---	------	-------

Sacamos tipo_avion_EmbraerE195

tipo_avion_EmbraerE195	-.007	.076	.009	1	.925	.993
------------------------	-------	------	------	---	------	------

Sacamos visibilidad

visibilidad	.001	.003	.108	1	.742	1.001
-------------	------	------	------	---	------	-------

Sacamos tipo_avion_Boeing737

tipo_avion_Boeing737	-.023	.069	.108	1	.742	.978
----------------------	-------	------	------	---	------	------

Sacamos tipo_avion_Boeing777

tipo_avion_Boeing777	.042	.112	.140	1	.709	1.043
----------------------	------	------	------	---	------	-------

Sacamos tipo_avion_AirbusA320neo

tipo_avion_AirbusA320neo	-.043	.068	.392	1	.531	.958
--------------------------	-------	------	------	---	------	------

Sacamos tipo_ruta_internacional

tipo_ruta_Internacional	.038	.054	.494	1	.482	1.039
-------------------------	------	------	------	---	------	-------

Sacamos tipo_ruta_nacional

tipo_ruta_Nacional	-.038	.054	.494	1	.482	.963
--------------------	-------	------	------	---	------	------

Sacamos tipo_avion_Boeing787

tipo_avion_Boeing787	.078	.104	.569	1	.450	1.082
----------------------	------	------	------	---	------	-------

Sacamos tipo_avion_AirbusA350

tipo_avion_AirbusA350	.061	.096	.395	1	.530	1.062
-----------------------	------	------	------	---	------	-------

Sacamos distancia_vuelo

distancia_vuelo	.000	.000	.426	1	.514	1.000
-----------------	------	------	------	---	------	-------

Sacamos tipo_avion_ATR72

tipo_avion_ATR72	-.041	.059	.485	1	.486	.960
------------------	-------	------	------	---	------	------

Sacamos tipo_avion_Manana

periodo_dia_Manana	-.034	.040	.716	1	.397	.966
--------------------	-------	------	------	---	------	------

Sacamos periodo_dia_Noche

periodo_dia_Noche	-.041	.058	.503	1	.478	.960
-------------------	-------	------	------	---	------	------

Sacamos dia_semana_Domingo

dia_semana_Domingo	-.058	.065	.782	1	.376	.944
--------------------	-------	------	------	---	------	------

Sacamos dia_semana_Viernes

dia_semana_Viernes	.058	.065	.782	1	.376	1.059
--------------------	------	------	------	---	------	-------

Sacamos periodo_dia_Tarde

periodo_dia_Tarde	.043	.039	1.217	1	.270	1.044
-------------------	------	------	-------	---	------	-------

Sacamos tipo_avion_AirbusA320

tipo_avion_AirbusA320	-.075	.060	1.562	1	.211	.928
-----------------------	-------	------	-------	---	------	------

Sacamos tipo_avion_EmbraerE190

tipo_avion_EmbraerE190	-.075	.059	1.593	1	.207	.928
------------------------	-------	------	-------	---	------	------

Sacamos dia_semana_Sabado

dia_semana_Sabado	-.089	.058	2.398	1	.122	.915
-------------------	-------	------	-------	---	------	------

Sacamos ocupacion_vuelo

ocupacion_vuelo	.002	.001	2.899	1	.089	1.002
-----------------	------	------	-------	---	------	-------

Sacamos dia_semana_Martes

dia_semana_Martes	-.111	.058	3.683	1	.055	.895
-------------------	-------	------	-------	---	------	------

Sacamos dia_semana_Lunes

dia_semana_Lunes	-.097	.056	2.971	1	.085	.907
------------------	-------	------	-------	---	------	------

Terminan quedando las siguientes variables significativas con un sig. < 0,05

		Variables in the Equation					
		B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a	temporada_alta	.470	.038	153.964	1	.000	1.600
	dia_semana_Jueves	-.160	.056	8.331	1	.004	.852
	dia_semana_Miercoles	-.107	.054	3.914	1	.048	.899
	condiciones_climaticas_Despejado	-1.599	.068	551.878	1	.000	.202
	condiciones_climaticas_Lluvia	-1.110	.076	211.854	1	.000	.329
	condiciones_climaticas_Niebla	-.694	.088	61.664	1	.000	.500
	condiciones_climaticas_Nublado	-1.684	.073	531.321	1	.000	.186
	congestion_aerea_Alta	.640	.048	181.189	1	.000	1.896
	congestion_aerea_Baja	-.478	.042	126.558	1	.000	.620
	tipo_avion_AirbusA330	.237	.084	7.915	1	.005	1.267
	Constant	.453	.068	44.597	1	.000	1.573

Tabla 4.18 Tabla de variables depuradas por su significancia.

4.2.5.4 Primer supuesto - Media 0 en el error

Este supuesto indica que, en promedio, los errores del modelo deben ser iguales a 0

H₀ (hipótesis nula): La media de las diferencias = 0 → Las predicciones no presentan un sesgo sistemático (el error medio es 0).

H₁ (hipótesis alternativa): La media de las diferencias ≠ 0 → Hay un sesgo sistemático en las predicciones.

One-Sample Test						
Test Value = 0						
	t	df	Sig. (2-tailed)	Mean Difference	95% Confidence Interval of the Difference	
					Lower	Upper
Difference between observed and predicted probabilities	.000	14999	1.000	.00000000	-.0070908	.0070908

Tabla 4.19 Tabla de Prueba T.

A partir de la prueba T se verifica que el supuesto de media cero de los errores tiene como resultado 0 diferencias.

El resultado obtenido indica que la media es exactamente 0 y el intervalo de confianza incluye el valor 0, lo que permite no rechazar la hipótesis nula.

Se puede concluir que el modelo no presenta sesgos en sus predicciones, cumpliendo así el supuesto de que los errores tienen media cero.

4.2.5.5 Segundo supuesto - Varianza constante (Homocedasticidad)

Para la hipótesis de la varianza constante se realizó la prueba de homogeneidad de varianzas.

La hipótesis es:

H₀ (hipótesis nula): Las varianzas son iguales. Hay homocedasticidad.

H₁ (hipótesis alternativa): Las varianzas son distintas. Hay heterocedasticidad.

Test of Homogeneity of Variances		Levene Statistic	df1	df2	Sig.
Difference between observed and predicted probabilities	Based on Mean	.102	2	14997	.903
	Based on Median	.066	2	14997	.936
	Based on Median and with adjusted df	.066	2	14996.827	.936
	Based on trimmed mean	.140	2	14997	.869

Tabla 4.20 Tabla de test de homogeneidad de las varianzas.

Como el valor de la significancia (p) es mayor a 0,05 en el caso que se basa en la media, se acepta la hipótesis nula, lo que indica que las varianzas son iguales entre los grupos. Esto significa que hay **homocedasticidad**, es decir que se cumple el supuesto de varianza constante.

Tercer supuesto - Distribución normal de los errores [No se cumple]

En esta prueba se ve si sigue una distribución normal.

La hipótesis es:

H₀ (hipótesis nula): Los datos provienen de una distribución normal.

H₁ (hipótesis alternativa): Los datos no provienen de una distribución normal.

Para visualizar que los residuos se distribuyen normalmente, se necesita realizar la prueba de normalidad de Kolmogorov-Smirnov y el gráfico Q-Q. La primera se encarga de comparar la distribución de los residuos con la distribución normal teórica. En los gráficos Q-Q normales se puede ver la diferencia entre las probabilidades pronosticadas y observadas


Tests of Normality

	Kolmogorov-Smirnov ^a		
	Statistic	df	Sig.
Difference between observed and predicted probabilities	.300	15000	.000

a. Lilliefors Significance Correction

Tabla 4.21 Tabla de Test de Normalidad.

En la prueba de Kolmogorov-Smirnov se ve que en la columna de significancia hay un valor menor a 0.05, por lo tanto, la hipótesis de que los residuos siguen una distribución normal es rechazada.






Figura 4.7 Q-Q plots para verificar la distribución normal de los residuos.

En ambos gráficos Q-Q, se puede notar que la función no sigue la recta, lo cual indica que los residuos no se distribuyen de forma normal.

Con los resultados obtenidos en la prueba, se puede concluir que se rechaza la hipótesis nula de normalidad. Por lo tanto, los datos no provienen de una distribución normal, a pesar de esto, se puede seguir con el análisis porque esta hipótesis es una de las que posteriormente se puede corregir mediante transformación de variables, pero en este caso no las vamos a realizar, por lo que el modelo por ahora sigue siendo válido en términos prácticos.

4.2.5.6 Supuesto 4 - No Multicolinealidad

En este supuesto se analiza la relación lineal, la correlación entre variables, que existe entre las variables predictoras del modelo.

La hipótesis es:

H₀ (hipótesis nula): No existe colinealidad severa entre las variables independientes.

H₁ (hipótesis alternativa): Hay colinealidad severa entre algunas variables independientes.

Se rechaza la hipótesis cuando se tiene un índice de condición > 30 , y en ese caso se considera que hay evidencia de colinealidad severa. Para esto hay que observar la columna del índice de condición, segunda columna, en la última fila.

Model	Dimension	Eigenvalue	Condition Index	(Constant)	Variance Proportions									
					temporada_alta	dia_semana_Jueves	dia_semana_Miercoles	condiciones_climaticas_Lluvia	condiciones_climaticas_Nieve	condiciones_climaticas_Nublado	condiciones_climaticas_Tormenta	congestion_area_Alta	congestion_area_Media	tipo_avion_AirbusA330
1	1	3.202	1.000	.02	.03	.02	.02	.01	.01	.02	.01	.01	.02	.01
	2	1.010	1.780	.00	.00	.17	.16	.03	.05	.07	.00	.17	.06	.00
	3	1.007	1.783	.00	.00	.04	.02	.02	.02	.12	.51	.00	.00	.09
	4	1.001	1.789	.00	.00	.01	.01	.37	.31	.00	.09	.01	.00	.00
	5	.998	1.791	.00	.00	.02	.02	.11	.33	.12	.09	.06	.02	.00
	6	.992	1.796	.00	.00	.20	.19	.01	.05	.00	.00	.20	.08	.00
	7	.931	1.855	.00	.00	.00	.01	.00	.00	.04	.04	.00	.00	.89
	8	.697	2.143	.00	.17	.44	.49	.00	.00	.01	.01	.00	.01	.00
	9	.581	2.347	.01	.69	.07	.04	.08	.03	.09	.03	.04	.06	.00
	10	.427	2.739	.00	.01	.00	.00	.24	.13	.33	.14	.26	.40	.00
	11	.154	4.567	.97	.10	.04	.04	.13	.07	.20	.08	.23	.34	.01

a. Dependent Variable: puerta_embarque

Tabla 4.22 Tabla Diagnóstico de colinealidad.

Como se puede observar, el índice de condición fue de **4.567**, lo cual significa que no existe colinealidad entre los residuos. Entonces, se puede aceptar la hipótesis, por quedar el índice por debajo de 20. En conclusión, las variables del modelo no presentan una colinealidad severa, y por tanto, sus coeficientes son estadísticamente estables.

4.2.5.7 Supuesto 5 - Errores no autocorrelados

En este supuesto el objetivo es analizar la independencia de los residuos entre sí.

La hipótesis es:

H₀ (hipótesis nula): Los residuos no están autocorrelados (es decir, son independientes).

H₁ (hipótesis alternativa): Los residuos están autocorrelados.

En el gráfico inferior, se presentan las autocorrelaciones parciales de los residuos del modelo para cinco retardos evaluando la independencia temporal entre ellos. Las barras azules representan los coeficientes de autocorrelación, mientras que las líneas negras representan el intervalo de confianza con un 95%. Como se puede observar, la mayoría de los coeficientes están dentro del intervalo, lo que indica que no existe evidencia estadísticamente significativa en que los residuos estén autocorrelados.




Figura 4.8 Gráfico de autocorrelación del error con 5 retardos.

La tabla muestra los resultados del test de autocorrelación mediante el estadístico de Box-Ljung evaluado para retardos del 1 al 5. El Objetivo es rechazar la hipótesis nula de que los residuos son independientes entre sí, para esto se puede ver la columna de significancia y se observa que todos los valores tiene un p-valor mayor a 0.05 entonces se concluye que no hay evidencia de autocorrelación.

Autocorrelations					
Series: Difference between observed and predicted probabilities					
Lag	Autocorrelation	Std. Error ^a	Box-Ljung Statistic		
			Value	df	Sig. ^b
1	-.008	.008	.853	1	.356
2	.002	.008	.928	2	.629
3	-.005	.008	1.258	3	.739
4	-.002	.008	1.292	4	.863
5	.003	.008	1.463	5	.917

a. The underlying process assumed is independence (white noise).

b. Based on the asymptotic chi-square approximation.

Tabla 4.23 Tabla de autocorrelación.

4.2.5.8 Supuesto 6 - Independencia entre variables independientes (VI) y el error

Se analiza la independencia entre las variables explicativas y el residuo realizado mediante un análisis bivariado.

La hipótesis es:

H₀ (hipótesis nula): Hay independencia de las variables explicativas y el residuo

H₁ (hipótesis alternativa): No existe independencia de las variables explicativas y el residuo.

El siguiente procedimiento verifica si se cumple el supuesto de que los residuos del modelo son independientes de las variables explicativas del mismo.

		temporada_alta	dia_semana_Jueves	dia_semana_Miercoles	condiciones_climaticas_Despejado	condiciones_climaticas_Lluvia	condiciones_climaticas_Niebla	condiciones_climaticas_Nublado	condiciones_climaticas_Tormenta	congestion_aerea_Alta	congestion_aerea_Baja	congestion_aerea_Media	tipo_avion_AirbusA330	observed and predicted probabilities
temporada_alta	Pearson Correlation	1	-.012	.013	-.005	.018 [*]	.000	-.006	-.004	.001	-.005	.004	.014	.000
	Sig. (2-tailed)		.134	.114	.503	.031	.970	.488	.628	.861	.528	.625	.097	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
dia_semana_Jueves	Pearson Correlation	-.012	1	-.162 ^{**}	.000	-.001	-.008	.003	.003	.004	-.005	.001	.001	.000
	Sig. (2-tailed)	.134		.000	.988	.910	.358	.709	.689	.602	.549	.861	.879	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
dia_semana_Miercoles	Pearson Correlation	.013	-.162 ^{**}	1	.006	-.003	-.004	-.004	.002	-.013	.011	-.001	.011	.000
	Sig. (2-tailed)	.114	.000		.471	.756	.658	.651	.817	.118	.165	.907	.189	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
condiciones_climaticas_Despejado	Pearson Correlation	-.005	.000	.006	1	-.382 ^{**}	-.250 ^{**}	-.522 ^{**}	-.264 ^{**}	.003	-.001	-.002	.003	.000
	Sig. (2-tailed)	.503	.988	.471		.000	.000	.000	.000	.713	.934	.828	.753	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
condiciones_climaticas_Lluvia	Pearson Correlation	.018 [*]	-.001	-.003	-.382 ^{**}	1	-.116 ^{**}	-.243 ^{**}	-.123 ^{**}	-.003	-.002	.004	-.005	.000
	Sig. (2-tailed)	.031	.910	.756	.000		.000	.000	.000	.718	.846	.624	.548	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
condiciones_climaticas_Niebla	Pearson Correlation	.000	-.008	-.004	-.250 ^{**}	-.116 ^{**}	1	-.159 ^{**}	-.080 ^{**}	.000	-.003	.003	.000	.000
	Sig. (2-tailed)	.970	.358	.658	.000	.000		.000	.000	.968	.743	.718	.962	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
condiciones_climaticas_Nublado	Pearson Correlation	-.006	.003	-.004	-.522 ^{**}	-.243 ^{**}	-.159 ^{**}	1	-.168 ^{**}	.000	.005	-.005	.013	.000
	Sig. (2-tailed)	.488	.709	.651	.000	.000	.000		.000	.975	.539	.555	.098	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
condiciones_climaticas_Tormenta	Pearson Correlation	-.004	.003	.002	-.264 ^{**}	-.123 ^{**}	-.080 ^{**}	-.168 ^{**}	1	-.001	-.002	.003	-.020 [*]	.000
	Sig. (2-tailed)	.628	.689	.817	.000	.000	.000	.000		.912	.791	.722	.017	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
congestion_aerea_Alta	Pearson Correlation	.001	.004	-.013	.003	-.003	.000	.000	-.001	1	-.409 ^{**}	-.406 ^{**}	.001	.000
	Sig. (2-tailed)	.861	.602	.118	.713	.718	.968	.975	.912		.000	.000	.929	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
congestion_aerea_Baja	Pearson Correlation	-.005	-.005	.011	-.001	-.002	-.003	.005	-.002	-.409 ^{**}	1	-.667 ^{**}	-.011	.000
	Sig. (2-tailed)	.528	.549	.165	.934	.846	.743	.539	.791	.000		.000	.179	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
congestion_aerea_Media	Pearson Correlation	.004	.001	-.001	-.002	.004	.003	-.005	.003	-.406 ^{**}	-.667 ^{**}	1	.010	.000
	Sig. (2-tailed)	.625	.861	.907	.828	.624	.718	.555	.722	.000	.000		.203	1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
tipo_avion_AirbusA330	Pearson Correlation	.014	.001	.011	.003	-.005	.000	.013	-.020 [*]	.001	-.011	.010	1	.000
	Sig. (2-tailed)	.097	.879	.189	.753	.548	.962	.098	.017	.929	.179	.203		1.000
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000
Difference between observed and predicted probabilities	Pearson Correlation	.000	.000	.000	.000	.000	.000	.000	.000	.000	.000	.000	.000	1
	Sig. (2-tailed)	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	
	N	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000	15000

*. Correlation is significant at the 0.05 level (2-tailed).

Tabla 4.24 Tabla de correlaciones.

Como el valor de significancia (p) en la última columna es mayor a 0,05 en todos los casos, no se rechaza la hipótesis nula, lo que indica que no existe correlación significativa entre las variables explicativas y el residuo. Esto significa que se cumple el supuesto de independencia, es decir, los errores son independientes de las variables explicativas del modelo.

4.2.5.9 Balanceo y puntos influyentes

Se analiza si existe presencia de outliers que tengan efecto directo sobre la pendiente de la función predictora. Ya que estos puntos tienen influencia directa en el cálculo de los Beta de la función. Se realiza un análisis de la distancia de Cook para cada una de las observaciones y consideramos que un punto es influyente cuando la distancia de Cook es mayor a 1.

La tabla que está a continuación calcula la distancia de cook para cada registro y luego lo ordena de forma descendente, y se puede observar en la columna COO_1 que ninguno tiene una distancia de Cook mayor a 1, siendo el valor más alto 0.00775 , entonces se puede afirmar que el conjunto de datos no posee puntos influyentes.

 PRE_1	 PGR_1	 RES_1	 grupo	 COO_1
.16358	0	.83642	2.00	.00775
.16358	0	.83642	3.00	.00775
.17107	0	.82893	2.00	.00744
.74144	1	-.74144	1.00	.00744
.74144	1	-.74144	2.00	.00744
.73100	1	-.73100	2.00	.00737
.17554	0	.82446	2.00	.00709
.17554	0	.82446	3.00	.00709
.75128	1	-.75128	3.00	.00704
.23975	0	.76025	1.00	.00623
.23975	0	.76025	2.00	.00623
.23975	0	.76025	3.00	.00623
.24822	0	.75178	1.00	.00619
.24822	0	.75178	2.00	.00619

Tabla 4.25 Tabla de Distancias de Cook mayores.

4.2.5.10 Evaluación del modelo

En el gráfico de abajo, se puede apreciar un eje horizontal donde están las distintas probabilidades que van de 0 a 1, se puede ver que a partir de 0.5 se clasifica como 1 a la probabilidad. Mientras que dentro de la tabla aparecen las observaciones reales donde el número 0 indica casos donde los vuelos no tuvieron demoras y el número uno indica casos donde los vuelos si tuvieron demoras. Este gráfico nos permite ver si el modelo clasificó de forma correcta, los “1” de forma correcta

deberían estar hacia la derecha del gráfico y los “0” hacia la izquierda donde las probabilidades son bajas.




Figura 4.9 Gráfico de predicciones sobre el punto de corte.

En la imagen que está debajo se muestra la matriz de confusión que nos resume el desempeño que tuvo el modelo de clasificación comparando los valores reales observados con los pronosticados predichos en función de un punto de corte, para en este caso como se puede ver es 0.5 .

Classification Table ^a					
Observed			Predicted		Percentage Correct
			demora 0	1	
Step 1	demora	0	9675	547	94.6
		1	3857	921	19.3
	Overall Percentage				70.6

a. The cut value is .500

Tabla 4.26 Matriz de confusión sin ajustar.

En esta matriz de confusión, se observa un FNR del 80.7% y un TNR del 94.6%. Este punto de corte predice bastante bien los vuelos no demorados, pero clasifica a la mayoría de los vuelos demorados como no demorados y no cumple con el

objetivo del estudio. Por lo tanto, se va a utilizar la curva ROC para encontrar otro punto de corte que mejore el FNR sin disminuir demasiado al TNR.

4.2.5.11 Curva ROC

La curva ROC permite evaluar el modelo haciendo enfoque en distintos puntos de corte. En el eje horizontal está la tasa de falsos positivos que sería la especificidad y en el eje vertical está la tasa de verdaderos positivos que sería la sensibilidad.




Figura 4.10 Curva ROC del modelo.

En este caso el área bajo la curva ROC toma un valor de 0.684 como se puede apreciar en la imagen abajo, dicho valor es indicador de una buena capacidad del modelo para clasificar entre los vuelos que van a tener demora y los que no la van a tener. Esta métrica es indistinta del punto de corte tomado y evalúa el rendimiento general en función de distintos umbrales.

Area Under the ROC Curve

Test Result Variable(s)	Area
Predicted probability	.684
The test result variable(s): Predicted probability has at least one tie between the positive actual state group and the negative actual state group. Statistics may be biased.	

Tabla 4.27 Área bajo la curva de la curva ROC.

A continuación, se analizó la tabla de coordenadas proporcionadas por la ROC, a fin de poder determinar cual es el punto óptimo de dicha curva, este punto se encuentra donde la diferencia entre la sensibilidad y la especificidad se acerque más a 0. Este valor se corresponderá con la coordenada de la curva ROC más óptima, es decir, el mejor punto de corte para el modelo.

En este caso, se determinó que el punto de corte ideal es: 0.318169147557044

Train

demora * PredictedValue Crosstabulation

			PredictedValue		
			.00	1.00	Total
demora	0	Count	4513	2642	7155
		% within demora	63.1%	36.9%	100.0%
	1	Count	1218	2127	3345
		% within demora	36.4%	63.6%	100.0%
Total	Count	5731	4769	10500	
	% within demora	54.6%	45.4%	100.0%	

Tabla 4.28 Matriz de confusión de entrenamiento ajustada.

Estos nuevos datos nos dejan ver que, tiene un FNR del 36.4% y un TNR del 63.1%, predice mejor que el punto de corte anterior los vuelos demorados y no baja demasiado el TNR, cumpliendo con los objetivos del estudio.

Para finalizar, se guardó el modelo y se corre nuevamente con los datos de prueba para ver el verdadero desempeño. Para ello se volverá a calcular la matriz de confusión, pero sobre los nuevos datos, comparando el valor real con el que predijo el modelo al correrlo.

Test

demora * PredictedValue Crosstabulation

			PredictedValue		
			.00	1.00	Total
demora	0	Count	1945	1122	3067
		% within demora	63.4%	36.6%	100.0%
	1	Count	525	908	1433
		% within demora	36.6%	63.4%	100.0%
Total		Count	2470	2030	4500
		% within demora	54.9%	45.1%	100.0%

Tabla 4.29 Matriz de confusión de test ajustada.

Esta matriz de confusión tiene un FNR del 36.6% y un TNR del 63.4%, siendo métricas bastante similares a las obtenidas con el conjunto de entrenamiento y validando que el modelo es estable, no está sobre ajustado, cumple con el objetivo del estudio y tiene mejores métricas que el obtenido con el punto de corte en 0.5.

4.3 Selección del mejor modelo

Para comparar el mejor modelo de cada técnica, se utilizan los resultados con el dataset de validación debido a que ilustran de manera más realista el desempeño de los modelos con datos no observados previamente.

Modelo	FNR	TNR
Regresión logística	36,6%	63,4%
LDA	37,4%	64,6%
Árboles Python	35,87%	60,94%
Árboles Modeler	31,8%	57,7%
K-NN	61%	71%

Tabla 4.30 Resultados del mejor modelo de cada técnica con el conjunto de validación

Como se definió en la introducción de este estudio, lo que se busca con la construcción del modelo predictivo es minimizar los costos de la empresa. Al inicio de esta sección, se definió que, desde la perspectiva del negocio, el costo de clasificar como no demorado un vuelo que lo está, es significativamente mayor al costo de clasificar un vuelo no demorado como demorado. En consecuencia, el modelo predictivo más útil es aquel que minimice la tasa de vuelos demorados clasificados como no demorados (FNR) pero que mantenga una tasa razonable de vuelos no demorados correctamente clasificados (TNR), para evitar que los usuarios del modelo pierdan confianza en el mismo. Dicha tasa razonable fue definida como una TNR del 60% o superior.

Teniendo en cuenta dichos requerimientos, se puede observar que si bien el mejor modelo de árbol en Modeler minimiza la FNR, no logra cumplir con el requerimiento de tener al menos una TNR de 60%, valor que de por sí ya había sido fijado relativamente bajo. En consecuencia, se lo descarta como modelo final.

Por otro lado, el segundo modelo con menor FNR, el mejor modelo de árbol en Python, presenta una FNR de 35,9% y una TNR de 61%. Por lo tanto, este será el modelo a utilizar para predecir los nuevos casos.

Si se adopta una perspectiva optimista y se asume que en la predicción de los nuevos casos se obtendrá un rendimiento idéntico al obtenido con el conjunto de validación, ¿Se podría decir que el modelo predictivo logra su cometido de reducir los costos de la empresa?

Se concluye que si, ya que si se asume que la aerolínea hoy en día no anticipa las demoras, significa que actualmente se tiene una situación equivalente a tener un 100% de FNR, lo que representa un costo muy elevado para el negocio por las razones desarrolladas anteriormente. En cambio, el modelo predictivo elegido permite bajar la FNR hasta un 35,9%, lo cual implica una gran reducción en los costos si se lo compara con la política mencionada.

Sin embargo, tampoco puede afirmarse que el modelo sea bueno, ya que una FNR de 35,9% sigue siendo bastante elevada, puesto que implica que alrededor de 1 de cada 3 vuelos demorados es clasificado incorrectamente.

A pesar de ello, el desempeño alcanzado permite concluir que el modelo constituye una herramienta útil de apoyo para la toma de decisiones y que su implementación podría generar mejoras relevantes respecto a la situación actual.

Etapa 2

5 Fase entendimiento de los datos

5.1 Descripción de los datos

Variable	Tipo	Rango / Valores posibles	Descripción
Edad	Numérica discreta	De 18 a 80	Edad del cliente de la aerolínea
Cantidad de vuelos	Numérica discreta	De 1 a 99	Cantidad de pasajes aéreos que el cliente compró en la aerolínea
Gasto acumulado	Numérica continua	De 71.25 a 253140.32	Gasto monetario del cliente en pasajes aéreos
Gasto acumulado extra	Numérica continua	De 3.21 a 47394.97	Gasto monetario del cliente en extras por fuera del pasaje aéreo
Cantidad de millas	Numérica discreta	De 0 a 541589	Cantidad de millas acumuladas como beneficio del programa de millas
Ingreso mensual	Numérica discreta	De 300 a 350075	Ingresos mensuales del cliente
Anticipación compra promedio	Numérica discreta	De 0 a 180	Promedio de días de anticipación de la compra del pasaje aéreo, entre todas las compras del cliente

Variable	Moda	Frecuencia	Descripción
Sexo	M	24973	Sexo del cliente
Provincia	Entre Ríos	2417	Provincia de origen del cliente
Ocupación	Empleado	11430	Trabajo del cliente
Clase preferida	Económica	37093	Clase de pasaje aéreo más comprada por el cliente
Programa millas	No	38052	Pertenencia del cliente al programa de millas
Canal de compra	Web	19743	Canal por el que el cliente compró la mayoría de las veces el pasaje aéreo

5.2 Análisis univariado

En conjunto con la información de la tabla previamente adjunta, se mostrarán, por variable, otros datos relevantes para el análisis. Para las variables categóricas se añadirá un recuento de frecuencias de los distintos valores que puede asumir, en conjunto con un gráfico de barras, también de la frecuencia. Para las numéricas se mostrará un histograma y un boxplot.

Edad




Figura 5.1 Histograma y boxplot de edad

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Edad	37.827400	37.565622	38.000	1.317763e+02	11.479385	18.00	80.00	62.00	17.0000	0.244425

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Edad	18.0000	18.0000	29.000	38.000	46.0000	57.0000	66.0000

En este gráfico se puede observar que la edad se distribuye entre los 18 y los 80 años, siendo la mayoría de los registros entre los 30 y 50 años, y tiene una forma de una distribución normal. Se puede ver un pico extraño en los 18 años, que puede deberse a que la aerolínea registra a los clientes menores de edad como de 18 años.

Cantidad de vuelos




Figura 5.2 Histograma y boxplot de cantidad de vuelos

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Cantidad vuelos	17.071860	15.086422	14.000	2.480759e+02	15.750424	1.00	99.00	98.00	15.0000	2.136964

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Cantidad vuelos	1.0000	2.0000	6.000	14.000	21.0000	54.0000	77.0000

La cantidad de vuelos sigue la forma de una distribución asimétrica a la derecha, teniendo la mayoría de los clientes de la aerolínea entre 1 y 20 vuelos. Además, se observan muchos valores de outliers superiores a los 60 vuelos, hasta los 100.

Gasto Acumulado




Figura 5.3 Histograma y boxplot de gasto acumulado

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Gasto Acumulado	6587.557023	4608.746545	3099.895	1.547506e+08	12439.879256	71.25	253140.32	253069.07	4912.7825	6.188107

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Gasto Acumulado	157.7499	341.7510	1404.575	3099.895	6317.3575	24375.0335	60509.9111

En las gráficas de gasto acumulado se observa que sigue la forma de una distribución asimétrica hacia la derecha, teniendo la mayoría de los valores entre 71.25 y 6317.3575 unidades monetarias. También se puede ver que hay muchos outliers desde 10000 hasta 253140.32 unidades monetarias.

Gasto Acumulado Extra




Figura 5.4 Histograma y boxplot de gasto acumulado extra

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Gasto Acumulado Extra	953.732059	641.840418	403.255	3.950614e+06	1987.615263	3.21	47394.97	47391.76	745.0675	7.197559

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Gasto Acumulado Extra	16.0098	41.3075	167.480	403.255	912.5475	3591.2985	9518.4340

En las gráficas de gasto acumulado extra se observa que sigue la forma de una distribución asimétrica hacia la derecha, teniendo la mayoría de los valores entre 3.21 y 912.5475 unidades monetarias. También se puede ver que hay muchos outliers desde 1500 hasta 47394.97 unidades monetarias.

Cantidad de Millas




Figura 5.5 Histograma y boxplot de cantidad millas

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Cantidad de Millas	6759.361980	2564.790133	0.000	5.536441e+08	23529.642402	0.00	541589.00	541589.00	0.0000	6.756850

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Cantidad de Millas	0.0000	0.0000	0.000	0.000	0.0000	38926.0500	121516.6100

En las gráficas de cantidad de millas se observa que sigue la forma de una distribución asimétrica hacia la derecha, teniendo la mayoría de los valores 0 millas, por tener a la mayoría de los clientes fuera del programa de millas. También se puede ver que los valores que figuran como outliers en el boxplot son los clientes que sí forman parte del programa de millas, teniendo como valor máximo 541589.00 millas.

Ingreso Mensual




Figura 5.6 Histograma y boxplot de ingreso mensual

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Ingreso Mensual	3062.882160	2658.044711	2100.000	1.429128e+07	3780.380841	300.00	350075.00	349775.00	2573.0000	24.256765

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Ingreso Mensual	300.0000	454.0000	1250.000	2100.000	3823.0000	8331.0500	14562.0300

En las gráficas de ingreso mensual se observa que sigue la forma de una distribución asimétrica hacia la derecha, teniendo la mayoría de los valores entre 300 y 3823 unidades monetarias. También se puede ver que hay muchos outliers desde 7000 hasta 350075 unidades monetarias. Esto demuestra que la mayoría de los clientes tienen ingresos nominalmente bajos.

Anticipación Compra Promedio




Figura 5.7 Histograma y boxplot de anticipación compra promedio

	Media	Media Recortada 5%	Mediana	Varianza	Desviación Estándar	Mínimo	Máximo	Rango	Rango Intercuartil (IQR)	Asimetría (Skewness)
Anticipación Compra Promedio	19.910660	17.365622	13.000	4.580276e+02	21.401580	0.00	180.00	180.00	22.0000	2.228481

	Percentil 1%	Percentil 5%	Percentil 25%	Percentil 50%	Percentil 75%	Percentil 95%	Percentil 99%
Anticipación Compra Promedio	0.0000	0.0000	5.000	13.000	27.0000	62.0000	99.0000

En las gráficas de anticipación compra promedio se observa que sigue la forma de una distribución asimétrica hacia la derecha, teniendo la mayoría de los valores entre 180 y 27 días en promedio de anticipación de compra. También se puede ver que hay muchos outliers desde 70 hasta 180 días.

Sexo

Sexo	Frecuencia	Frecuencia Relativa
M	24973	0.5
F	24515	0.49
No binario	512	0.01




Figura 5.8 Gráfico de barras de condiciones climáticas.

En el gráfico se puede observar que el sexo se distribuye principalmente entre el M, con 24973 registros y el F, con 24515. Abarcan casi todos los registros, quedando 512 registros como No binario.

Provincia




Figura 5.9 Gráfico de barras de provincias.

En el gráfico de provincias, se observa una distribución desigual, con la mayoría de los clientes concentrados en Entre ríos, Buenos Aires, Chaco, Salta, Córdoba, Mendoza, Santa Fe, CABA y Tucumán.

Ocupación




Figura 5.10 Gráfico de barras de ocupación.

En el gráfico de ocupación se puede observar que la mayoría de los clientes figuran como “Empleados”, sin definir formalmente en qué sector se desempeñan, seguido por Profesional independiente, Docente y Estudiante.

Clase Preferida

Clase Preferidas	Frecuencia	Frecuencia Relativa
Económica	37093	0.74
Ejecutiva	10937	0.22
Primera clase	1970	0.04




Figura 5.11 Gráfico de barras de clase preferida.

Las clases preferidas representan, por cada cliente, cual es la clase en la cual estos prefieren volar, se puede ver que la mayor predominancia la tiene la clase “Económica”, lo que tiene sentido con el nivel de salarios más bien reducidos de los clientes analizados anteriormente.

Programa de Millas

Programa de millas	Frecuencia	Frecuencia Relativa
No	38052	0.76
Si	11948	0.24




Figura 5.12 Gráfico de barras de programa millas.

En la distribución de programa de millas, se puede observar que la mayoría de los clientes no pertenecen al programa de millas, que también se puede ver en cantidad de millas que los clientes que tienen cero millas son la mayoría

Canal de Compras

Canal de Compras	Frecuencia	Frecuencia Relativa
Web	19743	0.39
App	18514	0.37
Agencia	7300	0.15
Aeropuerto	4443	0.09




Figura 5.13 Gráfico de barras de canal compra.

En el gráfico de canales de compra, se puede observar que la mayoría de los clientes realizan la compra del pasaje de sus vuelos por el canal web y por la app.

5.3 Análisis bivariado

A continuación se presenta el análisis bivariado de las variables que consideramos esenciales y de interés para poder entender los futuros clusters.

Matriz de Correlación




Figura 5.14 Matriz de correlación entre las variables numéricas.

Podemos ver en esta matriz que existen varias variables las cuales tienen una alta correlación entre sí. Si bien se ha realizado un análisis exhaustivo sobre las variables, se eligieron algunas de las variables con correlación mayor o igual a 0.5 para este estudio a fin de realizar el análisis bivariado.

Cantidad de vuelos VS Gasto acumulado




Figura 5.15 Gráfico de dispersión de las variables bajo estudio.

Se puede observar que a medida que aumenta la cantidad de vuelos del cliente aumenta la probabilidad de que el gasto acumulado sea superior, estando estas relacionadas, lo cual tiene sentido teniendo en cuenta que al comprar más vuelos aumenta el gasto acumulado. La diferencia observada en las grandes cantidades de vuelo en el gasto acumulado puede provenir de clientes que compran pasajes de primera clase o de ejecutiva, con los que compran en clase económica, haciendo que la relación entre las dos variables no sea enteramente lineal.

Cantidad de vuelos VS Cantidad de millas




Figura 5.16 Gráfico de dispersión de las variables bajo estudio.

En este gráfico se puede ver que a medida que aumentan la cantidad de vuelos del cliente, aumenta la cantidad de millas, aunque no linealmente por cambiar las diferencias en distancias entre los vuelos que toman la cantidad de millas que reciben por el vuelo. Además se observa la presencia de los clientes que no están en el programa de millas, teniendo estos hasta 100 vuelos, pero ninguna milla.

Clase preferida según ocupación




Figura 5.17 Gráfico de dispersión de las variables bajo estudio.

Se puede ver que las profesiones con estudios universitarios, ejecutivos o deportistas, tienen mayor predisposición a comprar pasajes en clase ejecutiva o en primera clase que los empleados, estudiantes o docentes.

Análisis multivariado

Ingreso mensual con el gasto acumulativo y la clase preferida




Figura 5.18 Gráfico de dispersión discriminado de las variables bajo estudio.

Se puede advertir que a medida que aumenta el gasto acumulativo y el ingreso mensual, hay más probabilidades de que el cliente compre pasajes en clase ejecutiva o en primera clase. Los grupos se solapan en determinados valores, pero luego de cierto valor en gasto acumulativo, los clientes sólo compran pasajes en primera clase. También se puede observar con los outliers que tienen un buen aumento del ingreso mensual que no necesariamente el cliente con ingresos altos va a comprar pasajes en primera clase.

Gasto acumulado, gasto acumulado extra y clase preferida




Figura 5.19 Gráfico de dispersión discriminado de las variables bajo estudio.

En este gráfico se puede observar la correlación alta entre gasto acumulado y gasto acumulado extra, están bastante relacionados entre sí, pero no forman completamente una línea. Además se puede ver mejor la relación entre gasto con el tipo de clase que compran los clientes, a mayor gasto acumulado o extra, más probabilidad de comprar pasajes en clase ejecutiva o primera clase.

6 Fase de modelado

6.1 Clustering Jerárquico

6.1.1 Definición del método

El clustering jerárquico es una técnica de minería de datos no supervisada que es utilizada para agrupar observaciones parecidas entre ellas y que sean lo más diferentes posible entre cada grupo. Se construye de manera jerárquica formando una estructura en forma de árbol o dendrograma. En lugar de asignar un número fijo de clusters como es en el caso de k means, se construye una estructura de clusters anidados.

Existen dos enfoques principales sobre la forma en cómo se van agrupando cada observación en clusters:

- En el enfoque aglomerativo, cada muestra se trata inicialmente como un clúster individual (parte de las hojas) y luego se van fusionando los clusters más similares hasta contener un único clúster (raíz).
- En el enfoque divisivo, se parte de un único cluster (raíz) que contiene todas la muestras y se van dividiendo en sub clusters más pequeños en cada paso hasta llegar a cada muestra individual (hoja).

Además dentro del enfoque aglomerativo, existen distintas formas de calcular la distancia de enlace, siendo esta la distancia que hay entre cada cluster. Las más utilizadas son:

- Enlace simple: La distancia entre los dos clusters es la mínima distancia entre un elemento de un cluster y uno del otro.
- Encadenamiento completo: La distancia entre clusters es la máxima distancia entre elementos de ambos clusters.
- Enlace promedio: Se calcula la distancia promedio entre todos los pares posibles del cluster.
- Método del centroide: Se calcula la distancia entre los centroides de cada clúster.
- Método Ward: Fusiona los clusters que minimizan el incremento en la suma de cuadrados dentro del cluster.

Dendograma (Ward)

Se obtuvo el siguiente dendograma utilizando el método de Ward:




Gráfico 6.1: Dendograma de clustering jerárquico

Coeficiente de siluetas




Gráfico 6.2: Diagrama de silueta de los modelos

Se puede observar en el gráfico de siluetas que el mejor coeficiente lo tiene el conjunto de 2 clusters, que es de 0.40. Por lo tanto, se procederá a analizar los resultados del conjunto de 2 clusters para ver cómo agrupo los registros el cluster jerárquico.

Proporción de clientes




Gráfico 6.3: Gráfico de torta para $k=2$

En este gráfico de tortas podemos observar las proporciones de los clusters sobre el total de clientes. Teniendo el cluster 0 a la mayoría de los clientes, con un 83.5% del total de los mismos.

Resultados de los cluster con $k=2$




Gráfico 6.4: Boxplot de ingreso mensual, $k=2$

El cluster 0 agrupó a los clientes con ingresos menores a 20000, y el cluster 1 agrupó a una mayor variedad de clientes con outliers que llegan hasta más de 100000




Gráfico 6.5: Boxplot de gasto acumulado, k=2

En el gasto acumulado se puede ver el mismo patrón observado anteriormente, el cluster 0 tiene los menores gastos y unos cuantos outliers que consumen varias veces más que el resto, mientras que el 1 concentra a los clientes que más gastaron y también posee varios outliers con consumos varias veces mayores al resto.




Gráfico 6.6: Boxplot de cantidad vuelos, k=2

En la cantidad de vuelos se observa que el cluster 0 agrupa a los clientes con menor cantidad de pasajes comprados y el cluster 1 a los de mayor cantidad, lo cual es coherente con lo visto y analizado anteriormente.




Gráfico 6.7: Boxplot de edad, k=2

En el caso de la edad de los clientes, tienen distribuciones similares en el núcleo de clientes, pero difieren en los valores extremos, teniendo clientes con edades más avanzadas el cluster 0 que el 1.




Gráfico 6.8: Ocupaciones por cluster, k=2

En las ocupaciones de los clientes se observa que el cluster 0 agrupa a las profesiones con menores salarios o a estudiantes y jubilados, en cambio el cluster 1 tiene a los ejecutivos y a los empresarios, que tienden a tener mejores ingresos que el resto.




Gráfico 6.9: Clase preferida por cluster

En la clase preferida, se puede ver que se mantiene la tendencia de los anteriores gráficos, en el cluster 0 los clientes compran en su mayoría la clase económica, y en el grupo 1 la primera clase y la clase ejecutiva.

6.1.2 Conclusión

En conclusión, se observan marcadas diferencias entre ambos clusters por lo cual se podría utilizarlos para definir los perfiles y cumplir con el objetivo de negocio de conservar a los mejores clientes con el vip en caso de demoras en el vuelo. El problema que tienen los dos clusters es que tienen un coeficiente de silueta bajo, que puede estar indicando que se podría separar mejor a los clientes, pero esto se verá cuando se lo compare con los clusters obtenidos con los otros modelos.

6.2 Cluster Bietápico

El clustering bietápico implementado por SPSS Modeler realiza una optimización automática del número de clusters en base a las variables de entrada.

6.2.1 Desarrollo

En una primera instancia, ejecutamos el modelo con la totalidad de las variables provistas, lo cual generó este primer modelo preliminar.




Gráfico 6.10: Barra de coeficiente de silueta, modelo preliminar

Este modelo divide los datos en 2 clusters diferentes, pero como podemos observar, cuenta con un coeficiente de silueta = 0.2, lo cual nos indica que esta clusterización es bastante pobre.

Por lo cual, antes de realizar un análisis un poco más exhaustivo en lo que respecta a este modelo, se procedió a ir quitando los predictores de menor importancia de forma progresiva hasta llegar a un resultado más fructífero.

Las columnas que se han ido eliminando hasta llegar a este mejor modelo son:

- sexo
- provincia

- edad
- programaMillas
- anticipacion_compra_promedio
- canal_compra

Con la remoción de estas variables predictoras, se llega al siguiente modelo:




Gráfico 6.11: Barra de coeficiente de silueta, modelo final

Este modelo ya presenta mejores resultados que el anterior, teniendo ahora un coeficiente de silueta = 0.5.




Gráfico 6.12: Estadísticos del modelo final

El modelo determinó que la mejor separación entre grupos era de 2, con una relación de 81.9/18.1 entre el grupo mayoritario y el minoritario. A continuación se muestran diversos graficos que indican la discriminación de grupos.

Cantidad de vuelos




Gráfico 6.13: Distribución de la cantidad de vuelos según clusters

En estos gráficos de frecuencias, podemos observar que en el cluster 2, que es donde se aglutinan la mayor cantidad de registros, podemos ver una alta frecuencia de cantidades de vuelos bajas, con una media de 11.85 vuelos, en contraste con el cluster 1, el cual cuenta con una distribución más homogénea, de vuelos, con una media de 40.64 vuelos, lo cual indica que los clientes del cluster 1 vuelan más que el 2.

Clase preferida




Gráfico 6.14: Distribución de clase preferida según clusters

En estos gráficos de barras, podemos visualizar que en el cluster 2, los clientes tienen a volar preferentemente en clase económica, mientras que si bien el el cluster 1 está clase sigue siendo la mayoritaria, la suma de clase ejecutiva y primera clase, es mayor a la clase económica, lo que lleva a la conclusión que estos clientes tienden a viajar en clases superiores.

Ocupación




Gráfico 6.15: Distribución de ocupación según cluster

En estos gráficos de barras se puede ver que en el cluster 1 hay una mayor proporción de clientes con ocupaciones de alto ingresos, como ejecutivos o empresarios. En cambio, en el cluster 2 está compuesto en su mayoría por clientes que son empleados, de los que se puede suponer que tienen menor poder adquisitivo que los ejecutivos o empresarios.




Gráfico 6.16: Predictores finales del modelo

6.2.2 Conclusión

Con esta tabla resumen, junto a las conclusiones sacadas anteriormente, podemos definir que los clusters discriminan de la siguiente forma:

- Cluster 1:
 - Tienden a volar más
 - Tienen una gran cantidad de millas
 - Son más propensos a volar en clases superiores
 - Gastan mucho dinero
 - Tienen salarios más altos
 - Tienen puestos de trabajo de alta jerarquía
- Cluster 2
 - Vuelan menos
 - Tienen cantidades de millas más modestas
 - Prefieren volar en clase económica
 - Gastan menores cantidad de dinero en los viajes
 - Tienen salarios más bajos
 - Tienden a tener puestos de trabajo de menor jerarquía

Y como este modelo cuenta con un coeficiente de silueta mejor, es un posible candidato de modelo final.

6.3 K - Means

6.3.1 Implementación

Antes de aplicar el algoritmo de agrupamiento, se realizó un preprocesamiento de datos. En esta instancia, se seleccionan sólo las variables numéricas del conjunto de datos, ya que el método de K - Means no soporta el trato de variables categóricas. Por lo tanto, se conservan las variables cuantitativas:

- Edad
- Cantidad de vuelos
- Gasto acumulado
- Gasto acumulado extra
- Cantidad de millas
- Ingreso mensual
- Anticipación de compra promedio

Luego, se aplicó una normalización al conjunto de datos mediante StandardScaler, transformando cada variable para que tenga media 0 y desvío estándar 1. Este procedimiento se realizó debido a la existencia de variables con escalas muy diferentes, lo que podría distorsionar los resultados del modelo, ya que este se basa en distancias euclidianas para asignar las observaciones a los centroides. Por lo tanto, sin la normalización, las variables con mayor escala tendrían una influencia desproporcionada en la formación de los grupos.

Posteriormente, se utilizó el método del codo para determinar el número óptimo de clusters. Este método consiste en probar varios valores de K, calcular el error total del modelo y graficar los resultados para identificar un punto de inflexión con forma de "codo". En este caso, se probó con valores de K que van de 2 a 10. Para cada uno, se calculó el valor de la inercia, es decir, la suma de los errores cuadráticos dentro de cada cluster. Este indicador refleja qué tan agrupadas se encuentran las observaciones dentro de cada cluster y tiende a reducirse al incrementar la cantidad de grupos.

El resultado se representa gráficamente en una curva de inercia en relación con el número de clusters. El punto óptimo se identifica observando el "codo" de la curva, que se relaciona con el valor de K a partir del cual la reducción de inercia se vuelve marginal. Por lo tanto, dicho K representa el equilibrio entre la simplicidad del modelo y la capacidad de capturar la estructura real de los datos.

Si bien este método nos proporciona una referencia objetiva para la selección de clusters, su resultado no será analizado como definitivo. La cantidad de clusters utilizados se determinará teniendo en cuenta criterios del contexto y la necesidad de negocio, buscando el equilibrio entre la calidad estadística de la segmentación y la

utilidad práctica para la toma de decisiones, que, en este caso, sería de determinar a qué pasajeros brindarles el voucher de comida y a cual otorgarles el acceso al VIP.




Gráfico 6.17: Método del codo

La curva no presenta un codo pronunciado y único, sino el descenso es gradual y continuo. Se observan mayores reducciones de inercia para los valores de K entre 2 y 4. A partir de K = 5 la tasa de reducción empieza a estabilizarse, indicando que los rendimientos decrecen al incrementar la cantidad de clusters.

Dado a que este método no señala un punto de inflexión claro, se recurrirá a utilizar una métrica complementaria.

Se hará el uso de la métrica *coeficiente de silueta* para evaluar la calidad de los agrupamientos generados por K-means. Esta métrica compara, para cada observación, la cohesión dentro de su propio cluster con la separación respecto a los demás. Los valores del silhouette score oscilan entre -1 y 1, donde valores cercanos a 1 indican que las observaciones están bien asignadas a sus respectivos clusters, mientras que valores cercanos a 0 o negativos sugieren solapamiento o mala asignación.

En el gráfico correspondiente, se representa el valor promedio del *coeficiente de silueta* para cada cantidad de clusters. El número óptimo de clusters se identifica como aquel que maximiza esta medida, indicando una configuración en la que los grupos son internamente compactos y externamente bien separados.




Gráfico 6.18: Coeficiente de Silueta

Como se observa tanto en la gráfica como en la tabla, el coeficiente de silueta presenta su valor máximo en $K = 2$ (0,5988), indicando que con dos clusters las observaciones se encuentran bien asignados en los grupos. Las observaciones presentan una pequeña distancia intra-grupos y una distancia grande inter-grupos, es decir, buena separación entre clusters.

A partir de $K = 3$ el coeficiente cae considerablemente (0,4775), y de forma abrupta en $K = 4$ (0,2250).

Por lo tanto, el coeficiente de silueta evidencia que con $K = 2$ se proporciona la mejor calidad de agrupamiento, siendo la única alternativa que supera el umbral de 0,50 (>50 indica separación y cohesión satisfactoria entre clusters). En contraste, para valores de $K > 4$, el coeficiente se encuentra en torno a 0,25, lo que indica menor diferenciación entre grupos y un mayor grado de solapamiento entre ellos.

Al complementar este análisis de coeficiente de silueta con los resultados del método del codo, que también identificó a $K = 2$ y $K = 3$ como mejores opciones de clusters, se profundizará el estudio con ambas configuraciones para identificar cual es la mejor opción de clusters para separar de manera satisfactoria los clientes de la aerolínea.

6.3.2 Segmentación K = 2

La configuración con dos clusters generó una separación de la muestra en dos grupos con perfiles claramente distintos.




Gráfico 6.19: Proporción de la población entre cluster

En el cluster 0 se concentra la mayoría de los pasajeros, con 45.726 personas que representan el 91.8% de la población total de pasajeros con demora.

El cluster 1, en cambio, agrupa a una minoría significativa de pasajeros pero con un alto valor estratégico; que ya veremos por qué es así. En este grupo, se encuentran 4.064 pasajeros que representan el 8.2% de la población total.

A continuación, se presentan de forma gráfica las principales características de cada cluster, con el objetivo de facilitar la interpretación de los perfiles de pasajeros representados en cada grupo.

Distribución de clase preferida por cluster




Gráfico 6.20: Distribución de clase preferida por cluster

En el cluster 0, el 78.4% de los pasajeros habitualmente viaja en clase económica, mientras que sólo el 19.8% opta por viajar en clase ejecutiva y un marginal 1.8% en

primera clase. Se puede inferir que el perfil de este grupo de pasajeros, prioriza el costo por sobre el confort del vuelo.

Por el contrario, el cluster 1 tiene una distribución más equilibrada con respecto al cluster 0 pero claramente orientada a las clases más costosas. El 45.9% de los pasajeros vuela en clase ejecutiva, el 28.1% en primera clase y solo el 26% viaja en clase económica. Es decir, el 74% de los pasajeros del cluster 1 viaja en clases superiores a la económica.

Se puede observar una segmentación claramente diferenciada entre los pasajeros VIP (cluster 1), caracterizados por su alto valor estratégico para el negocio, y los pasajeros generales (cluster 0), que constituyen la mayor parte de la población analizada.

Afiliación al programa de millas por cluster




Gráfico 6.21: Programa de millas por cluster

En el cluster 0, el 79.2% de los pasajeros no está afiliado al programa, lo cual nos indica un perfil de pasajero que no viaja frecuentemente al punto de no encontrar suficiente incentivo para adherirse al programa de fidelización.

En el cluster 1 la situación se invierte, ya que el 58.9% de los pasajeros pertenecientes a este grupo están adheridos al programa. Este dato es muy importante, porque este programa implica un vínculo activo y sostenido con la aerolínea. Esto indica que los pasajeros que se encuentran en este cluster, vuelan con mayor frecuencia y tienen un grado de fidelización con la aerolínea. Sin embargo, se puede destacar que hay un 41.1% de pasajeros del cluster 1 que no está afiliado al programa a pesar de viajar en clases altas, lo cual puede ser una oportunidad de negocio para la aerolínea en términos de captación para el programa.

Gastos acumulados promedio por cluster




Gráfico 6.22: Gasto acumulado por cluster

En este gráfico se puede ver de forma clara el perfil de pasajero en cada cluster. El gasto acumulado promedio histórico en pasajes del pasajero perteneciente al cluster 1 es de 36.670 USD, que equivale a un gasto acumulado 9 veces mayor al del pasajero promedio perteneciente al cluster 0, que es de 4.003 USD.

Esto es interesante de ver a nivel negocio, porque aunque el cluster 1 represente a la minoría (8.2%), concentran una proporción desproporcionadamente alta de ingresos, haciendo que estos pasajeros se vuelvan de alto valor para la aerolínea.

Profesiones predominantes por Cluster




Gráfico 6.23: Profesión predominante por cluster

En el cluster 0, tiene como profesión predominante a Empleado abarcando un 24.9% de la población del grupo. Luego, le sigue la profesión de docente con un

9.5%, profesión independiente con 9.5%, estudiante con 7.9% y por último el comerciante con un 7.5%.

Por otro lado, el cluster 0 tiene como profesión predominante al ejecutivo que representa al 45.3% de la población del grupo. Luego, le sigue la profesión de empresario con 27.5%, deportista con un 19.7%, médico con 3.8% y por último la profesión de abogado con un 1.3%.

Se puede inferir que en el cluster 0, el perfil se alinea más a un viajero de ocio o turista estándar, que probablemente financie sus propios pasajes y que los viajes sean de vacaciones.

En cambio, el 73% de los pasajeros pertenecientes al cluster 1 corresponden a la cúpula corporativa (ejecutivos y empresarios), lo cual indicaría que los viajes se tratan de “viajes de negocios” generalmente financiados por empresas. También es interesante notar que casi un 20% son deportistas. Esta profesión suele requerir viajar constantemente a competiciones y generalmente son pagadas por clubes o sponsor, y que priorizan la comodidad.

Canal de compra y sexo por Clusters




Gráfico 6.24: Canal de compra y sexo por cluster

A diferencia de las variables anteriores, en el análisis de canal de compra y la distribución por sexo demuestra una homogeneidad entre los grupos.

Por lo tanto, estas variables no resultan determinantes para diferenciar a los segmentos entre sí.

Validación estadística de clusters mediante diagramas de caja (Boxplots)

Tras analizar la distribución general de las variables, se utilizarán diagramas de caja (boxplots) para evaluar visualmente la separación entre los clusters y comparar sus rangos con respecto a la población total.

En este caso, es muy probable que la media poblacional se solape con el rango intercuartílico del cluster 0, ya que representa el 92% de la población.

Por lo tanto, el objetivo de esta validación será comprobar que no exista solapamiento entre los rangos intercuartílicos de los distintos clusters, garantizando así la heterogeneidad de los grupos.

A continuación se presentan los gráficos de cada de todas las variables:

Distribución de Edad




Gráfico 6.25: Boxplot de Edad, K = 2

Se observa un solapamiento significativo en los rangos intercuartílicos (IQR) de ambos clusters, compartiendo la franja central de datos (de 33 a 46). Las medias de cada grupo (37.65 y 39.80) se encuentran próximas entre sí y a la media poblacional (37.83). En consecuencia, esta variable presenta un comportamiento homogéneo y no resulta determinante para la segmentación de perfiles.

Cantidad de vuelos




Gráfico 6.26: Boxplot de Cantidad de vuelos, K = 2

No existe solapamiento en los rangos intercuartílicos (IQR) de los clusters, presentando una separación total entre las franjas centrales de datos.

Las medias de cada grupo (13.77 y 54.29) se encuentran fuertemente distanciadas. En consecuencia, esta variable presenta un comportamiento heterogéneo entre clusters y resulta determinante para segmentar a los pasajeros.

Gasto acumulado




Gráfico 6.27: Boxplot de Gasto acumulado, K = 2

No existe solapamiento en los rangos intercuartílicos (IQR) de los clusters, presentando una separación total entre las franjas centrales de datos.

Las medias de cada grupo (4.003 y 35.670) se encuentran fuertemente distanciadas. En consecuencia, esta variable presenta un comportamiento heterogéneo entre clusters y resulta determinante para segmentar a los pasajeros. Además, se puede observar que las medias de los clusters difieren con la media poblacional

Gastos acumulados extra




Gráfico 6.28: Boxplot de Gasto acumulado extra, K = 2

No existe solapamiento en los rangos intercuartílicos (IQR) de los clusters, presentando una separación total entre las franjas centrales de datos.

Las medias de cada grupo (566 y 5.299) se encuentran fuertemente distanciadas. En consecuencia, esta variable presenta un comportamiento heterogéneo entre clusters y resulta determinante para segmentar a los pasajeros.

Además, se puede observar que las medias de los clusters difieren con la media poblacional

Cantidad de Millas




Gráfico 6.29: Boxplot de Cantidad de millas, $K = 2$

En este caso pasa algo particular, ya que más del 75% de la población del cluster 0 no están adheridos al plan de millas, ocasionando que el IQR del grupo sea [0-0]. En contraste, el Cluster 1 muestra una enorme dispersión ([0.00 - 80683.00]). Con medias distanciadas (2758.97 frente a 51718.52), esta variable es fuertemente heterogénea y un diferenciador clave para la segmentación de pasajeros.

Ingreso mensual




Gráfico 6.30: Boxplot de Ingreso mensual, $k = 2$

No existe solapamiento en los rangos intercuartílicos (IQR) de los clusters, presentando una separación total entre las franjas centrales de datos.

Las medias de cada grupo (2.616 y 8.089) se encuentran distanciadas. En consecuencia, esta variable presenta un comportamiento heterogéneo entre clusters y resulta determinante para segmentar a los pasajeros.

Anticipación de compra promedio




Gráfico 6.31: Boxplot de Anticipación de compra promedio, $K = 2$

Se observa un solapamiento significativo en los rangos intercuartílicos (IQR) de ambos clusters, compartiendo la franja central de datos (de 5.00 a 19.00). Si bien las medias de cada grupo presentan una leve diferencia (20.44 y 13.99) en torno a la media poblacional (19.91), el fuerte solapamiento de las cajas indica que esta variable presenta un comportamiento mayormente homogéneo. En consecuencia, no resulta un factor determinante para la segmentación estricta de perfiles.

6.3.3 Segmentación $K = 3$

La configuración con tres clusters generó una separación de la muestra en tres grupos con perfiles distintos, subdividiendo la población original con la siguiente proporción.




Gráfico 6.32: Proporción de la población entre clusters

En el cluster 1 se concentra la mayoría de los pasajeros, con 43.467 personas que representan el 87.3% de la población total de pasajeros con demora.

Por su parte, a diferencia con $K = 2$, los perfiles de pasajeros minoritarios se subdividieron entre sí, generando un cluster con 5.676 pasajeros (Cluster 0) que representa el 11,4% de la población y otro aún más chico de 647 pasajeros (cluster 2), que representa solo el 1,3% de la población.

Al igual que en la configuración anterior, se llevó a cabo el análisis comparativo de medias y rangos intercuartílicos (IQR) para validar la separación estadística de los tres clusters. Por razón de no hacer más extenso el informe, vamos a omitir mostrar los boxplots. Los resultados de dicho análisis se presentarán consolidados en el apartado de evaluación de configuraciones.

6.3.4 Comparativa de modelos y selección del K óptimo

Con el objetivo de determinar la configuración de clusters más adecuada para el negocio en cuestión, se compararon las configuraciones $K = 2$ y $K = 3$ (K óptimos en el método del “codo”) analizando las medias de cada cluster por variable y su relación con la media poblacional. En la siguiente tabla, se muestran únicamente aquellos clusters y variables donde los IQR no se solapan entre sí, es decir, donde la separación entre grupos es estadísticamente significativa y por lo tanto los grupos son heterogéneos entre sí. Los casos marcados con “-” indican que los IQR de los clusters se solapan en esa variable, por lo que no aportan poder discriminante real.

MATRIZ COMPARATIVA DE MEDIAS POBLACIONALES Y SEGMENTOS (K=2 vs K=3)						
Variable	Media Población	Configuración K = 2		Configuración K = 3		
		Cluster 0	Cluster 1	Cluster 0	Cluster 1	Cluster 2
Edad	37,83	-	-	-	-	-
Cantidad de vuelos	17,08	13,77	54,29	-	12,46	-
Gasto acumulado	6.587	4.003	35.670	21.363	3.496	81.757
Gasto extra	953	566	5.299	3.054	497	12.678
Ingreso mensual	3.063	2.616	8.089	-	2.443	-
Cantidad de millas	6.755	2.758	51.718	-	2.215	-
Anticipación de compra promedio	-	-	-	-	-	-

Tabla 6.1: Tabla comparativa de medias y segmentos

En la configuración $K = 2$, las variables “cantidad de vuelos”, “gasto acumulado”, “gasto extra”, “ingreso mensual” y “cantidad de millas” logran separar a ambos clusters sin solapamiento de su rango intercuartílico (IQR). El cluster 0, se posiciona por debajo de la media en todas las variables, mientras que el cluster 1 supera ampliamente los valores de la media, hasta el punto de ser 9 veces superiores,

como es el ejemplo del gasto acumulado y casi 19 veces en cantidad de millas. La edad y la anticipación de compra promedio no discriminan en ninguna configuración.

En la configuración $K = 3$, la situación cambia con respecto a la configuración anterior. Solo las variables “gasto acumulado” y “gasto extra” logran separar los tres clusters sin solapamiento, mostrando una división clara:

- Cluster 1: Gasto bajo
- Cluster 0: Gasto medio
- Cluster 2: Gasto alto

El resto de las variables como “cantidad de vuelos”, “ingreso mensual” y “cantidad de millas” solo discriminan al cluster 1 del resto, pero no pueden separar de forma efectiva al cluster 0 del cluster 2.

En conclusión, si bien $K = 3$ logra una segmentación más específica en las variables de gasto, lo hace sacrificando poder discriminante en las demás variables. $K = 2$, en cambio, logra una separación limpia y consistente de cinco variables de manera simultánea. Esto, sumado a que $K = 2$ tiene un mejor coeficiente de silueta (0.5988 vs 0.4775), calculado en el primer apartado, nos indica que es estadísticamente la mejor elección.

Además, esta configuración de clusters se alinea perfectamente a los objetivos de negocio de la aerolínea, que es definir a los pasajeros que obtendrán un acceso al VIP y otros que recibirán una voucher de comida.

Por lo tanto, $K=2$ se consolida como la configuración óptima para este problema.

6.4 Análisis de componentes principales

Con el objetivo de facilitar la visualización e interpretación de los perfiles de clientes identificados mediante técnicas de clustering, se aplicó un Análisis de Componentes Principales (ACP) sobre las variables numéricas, previamente estandarizadas debido a la diferencia significativa entre las escalas de las mismas. La matriz de correlaciones presentada en el análisis exploratorio evidenció la presencia de algunas correlaciones moderadas y altas entre variables relacionadas con el comportamiento de consumo de los clientes, por lo que el ACP resulta una herramienta utilizable para explorar posibles estructuras subyacentes y obtener una representación visual de los clusters.

CP	Autovalor	% Varianza	% Acumulado
CP1	3.079	43.988	43.988
CP2	1.068	15.252	59.239
CP3	0.925	13.213	72.453
CP4	0.776	11.081	83.533
CP5	0.586	8.373	91.906
CP6	0.477	6.815	98.721
CP7	0.09	1.279	100

Tabla 6.2 Varianza explicada de las componentes principales




Gráfico 6.33 Varianza acumulada explicada

Las dos primeras componentes principales explican conjuntamente el 59,24% de la variabilidad total del conjunto de datos. Si bien esta representación implica una reducción de información respecto del espacio original, su selección permite una visualización bidimensional de los clusters de clientes.

Variable	CP1	CP2
edad	0.076	0.714
cant_vuelos	0.443	0.045
gasto_acumulado	0.523	-0.102
gasto_acumulado_extra	0.503	-0.114
cantidad_millas	0.409	-0.097
ingreso_mensual	0.312	0.07
anticipacion_compra_promedio	-0.081	-0.671

Tabla 6.3 Cargas factoriales de las dos primeras componentes principales

La primera componente principal está asociada principalmente con dos grupos de variables. Por un lado, las variables de carácter económico, `gasto_acumulado`, `gasto_acumulado_extra` e `ingreso_mensual`. Por otro lado, las variables relativas a la frecuencia de vuelos, `cant_vuelos` y `cantidad_millas`. Ambos grupos presentan una contribución positiva en la componente, por lo que la misma puede interpretarse como una medida del valor económico aportado por el cliente, considerando tanto su nivel de gasto como su actividad y grado de fidelización dentro de la empresa.

Por lo tanto, clientes con puntuaciones elevadas en la primera componente principal serían candidatos particularmente adecuados para ser compensados con un pase VIP ante una demora predicha, dado que representan clientes de alto valor para la organización.

La segunda componente principal está asociada principalmente a la edad del cliente y a la anticipación promedio de compra. Ambas variables presentan contribuciones importantes en la componente, aunque de signo opuesto, por lo que la misma puede interpretarse como una medida del perfil de planificación de viaje del cliente. De esta forma, permite diferenciar distintos perfiles según su edad y la anticipación con la que suelen realizar sus compras.

En particular, clientes con puntuaciones altas en esta componente tienden a ser de mayor edad y a realizar sus compras con menor anticipación, mientras que clientes con puntuaciones bajas suelen ser más jóvenes y planificar sus viajes con mayor antelación.




Gráfico 6.34 Clusters visualizados en el subespacio generado por ACP

La Figura X.2 muestra la proyección de los clientes sobre las dos primeras componentes principales, coloreados según el cluster asignado por K-Means. Se observa que la separación entre grupos se produce principalmente a lo largo de la primera componente principal, asociada al gasto acumulado, la frecuencia de vuelos y la acumulación de millas. En consecuencia, el Cluster 1 agrupa a los clientes de mayor valor económico y fidelidad, mientras que el Cluster 0 concentra a los clientes de menor consumo, lo que constituye la base para la asignación diferencial de beneficios ante una demora predicha.

7 Análisis de los resultados del modelo predictivo y descriptivo

El modelo de árboles de decisión (Python) identificó 3.821 vuelos con demora sobre los 5.000 analizados en el dataset “*nuevosVuelos*”, lo que representa una tasa de detección del 76,42%. Como resultado, 49.790 de los 50.000 clientes del conjunto se vieron expuestos a una demora predicha y son en consecuencia, candidatos a recibir una compensación.




Figura 7.1 *Distribución de clientes por cluster afectados por una demora predicha*

De los 49.790 clientes afectados, 45.726 (91,84%) pertenecen al Cluster 0, el segmento mayoritario. Se trata de pasajeros de perfil general, viajeros principalmente en clase económica, con baja frecuencia de vuelo, sin afiliación al programa de millas y un gasto acumulado histórico promedio de USD 4.003. Para este grupo, el voucher de restaurante representa la compensación adecuada, suficiente para mitigar la insatisfacción inmediata sin incurrir en un costo desproporcionado respecto al valor esperado del cliente.

Los 4.064 clientes restantes (8,16%) corresponden al Cluster 1, la minoría de alto valor para el negocio. Son ejecutivos y empresarios que viajan predominantemente en clase ejecutiva o primera, con ingresos mensuales promedio de USD 8.089 y un gasto acumulado histórico de USD 36.670, nueve veces superior al del Cluster 0 y con alta afiliación al programa de millas. Para este segmento, el acceso a sala VIP es la compensación correcta, ya que se alinea con el estándar de servicio que estos pasajeros esperan y protege una fuente de ingresos sumamente valiosa para la aerolínea.

En resumen, la combinación de ambos modelos permite cumplir el objetivo de negocio de asignar compensaciones diferenciadas según el valor del cliente, minimizando el costo total de las demoras, a la vez que aumenta la probabilidad de retención de los pasajeros de mayor impacto económico para DS Airlines. Aplicando esta estrategia sobre el conjunto de 5.000 vuelos analizados, de los cuales se predijeron 3.821 con demora, se identificaron 49.790 clientes potencialmente afectados, muchos de ellos en múltiples ocasiones. Como resultado, se asignaron 250.837 vouchers de comida y 22.284 accesos VIP, totalizando 273.121 compensaciones distribuidas según el valor y perfil de cada cliente.

Bibliografía

Wikipedia contributors. (s.f.). *Vuelo ferry*. Wikipedia, La enciclopedia libre.
https://es.wikipedia.org/wiki/Vuelo_ferry

Despegar. (s.f.). *Vuelos a Buenos Aires*.
<https://www.despegar.com.ar/vuelos/bue/vuelos-a-buenos+aires>

Wikipedia contributors. (s.f.). *Airbus A330*. Wikipedia, La enciclopedia libre.
https://es.wikipedia.org/wiki/Airbus_A330

Wikipedia contributors. (s.f.). *ATR 72*. Wikipedia, La enciclopedia libre.
https://es.wikipedia.org/wiki/ATR_72

Wikipedia contributors. (s.f.). *Boeing 737*. Wikipedia, La enciclopedia libre.
https://es.wikipedia.org/wiki/Boeing_737

SeatMaps. (s.f.). *Embraer E190 – Aerolíneas Argentinas*.
<https://seatmaps.com/es/airlines/ar-aerolineas-arg/embraer-e190/>

LATAM Airlines. (s.f.). Lounges and facilities.
<https://www.latamairlines.com/gb/en/experience/airport/lounges-and-facilities/miami#fees>

Aeropuertos Argentina. (s.f.). Gastronomía – Ezeiza.
<https://tienda.aeropuertosargentina.com/ezeiza/categoria-producto/gastronomia/>

Anexo

Tablas del análisis bivariado

Ocupación de vuelo (%)	Proporción de demora	Observaciones
0 - 5	NaN	0
5 - 10	0.000000	1
10 - 15	0.000000	8
15 - 20	0.260870	23
20 - 25	0.439024	41
25 - 30	0.344086	93
30 - 35	0.289308	159
35 - 40	0.283582	268
40 - 45	0.345372	443
45 - 50	0.334400	625
50 - 55	0.340347	808
55 - 60	0.315217	1012
60 - 65	0.307276	1292
65 - 70	0.291080	1491
70 - 75	0.305571	1777
75 - 80	0.304709	1805
80 - 85	0.307061	1827
85 - 90	0.324723	1626
90 - 95	0.361881	1191
95 - 100	0.392157	510

Tabla 1 Proporción de demora por intervalo de ocupación_vuelo

Visibilidad (Rango de KM)	Proporción de demora	Observaciones
0 - 1	0.530026	383
1 - 2	0.533026	651
2 - 3	0.508661	635
3 - 4	0.608856	271
4 - 5	0.612676	284
5 - 6	0.286364	440
6 - 7	0.272358	492
7 - 8	0.266533	499
8 - 9	0.274319	514
9 - 10	0.244742	523
10 - 11	0.278481	474
11 - 12	0.309942	513
12 - 13	0.308765	502
13 - 14	0.284836	488
14 - 15	0.263158	513
15 - 16	0.285714	497
16 - 17	0.291353	532
17 - 18	0.291353	532
18 - 19	0.272917	480
19 - 20	0.272549	510
20 - 21	0.267823	519
21 - 22	0.269903	515
22 - 23	0.289179	536
23 - 24	0.272059	544
24 - 25	0.269811	530

25 - 26	0.286822	516
26 - 27	0.273423	523
27 - 28	0.269307	505
28 - 29	0.284861	502
29 - 30	0.298148	540
30 (valor entero)	0.189189	37

Tabla 2 Proporción de demora por intervalo de visibilidad

Distancia de vuelo (Rango de 500 millas)	Proporción de demora	Observaciones
8535 - 9535	0.394231	104
4035 - 4535	0.358696	184
5035 - 5535	0.357143	126
7035 - 7535	0.352941	238
3535 - 4035	0.351312	686
4535 - 5035	0.339806	309
2535 - 3035	0.330118	933
3035 - 3535	0.324885	434
1035 - 1535	0.323477	1691
2035 - 2535	0.323077	520
1535 - 2035	0.316190	1050
535 - 1035	0.313680	2595
35 - 535	0.310197	5374
9535 - 10035	0.306931	101
7535 - 8035	0.306723	238
9535 - 10035	0.300000	110
8035 - 8535	0.284091	88

9035 - 9535	0.260274	219
5535 - 6035	NaN	0
6035 - 6535	NaN	0
6535 - 7035	NaN	0

Tabla 3 Proporción de demora por intervalo de distancia vuelo. Orden descendente por proporción de demora.

Día de semana	Proporción de demora	Observaciones
Viernes	0.344235	2385
Domingo	0.337163	2263
Sábado	0.317432	2243
Lunes	0.313953	1978
Martes	0.313464	1946
Miércoles	0.303397	2149
Jueves	0.294204	2036

Tabla 4 Proporción de demora por día de semana, ordenada por proporción descendente.

Puerta de embarque	Proporción de demora	Observaciones
12	0.373418	316
26	0.365248	282
28	0.364548	299
17	0.360502	319
10	0.351852	270
32	0.350158	317
40	0.349398	332
14	0.342756	283
16	0.341818	275

34	0.341772	316
37	0.341216	296
8	0.339869	306
23	0.338323	334
41	0.337662	308
31	0.3367	297
18	0.335443	316
46	0.333333	285
44	0.330218	321
47	0.330097	309
49	0.327974	311
5	0.326923	312
25	0.322581	310
42	0.322188	329
15	0.321192	302
11	0.32	325
30	0.317568	296
27	0.315789	304
19	0.315615	301
4	0.314488	283
7	0.314024	328
1	0.31348	319
21	0.311419	289
20	0.311419	289
2	0.307937	315
43	0.304498	289
39	0.301075	279
29	0.300292	343

3	0.298013	302
36	0.295181	332
38	0.295031	322
22	0.29316	307
45	0.28481	316
24	0.284314	306
9	0.280645	310
48	0.279152	283
33	0.27673	318
6	0.274021	281
35	0.263514	296
13	0.254658	322

Tabla 5 Proporción de demora por puerta de embarque, ordenada por proporción descendente.

Aeropuerto Origen	Proporción de demora	Observaciones
MAD	0.411765	153
MIA	0.398281	349
IAH	0.39759	83
MDZ	0.383178	107
BSB	0.380952	105
POA	0.372093	129
JFK	0.360714	280
ASU	0.357143	112
SCL	0.35567	194
GUA	0.354167	96
CLO	0.346801	297
LIM	0.340633	411
SJO	0.338843	121
BAQ	0.336283	339
FLN	0.330709	127
ROS	0.326923	156
PEI	0.326087	368

COR	0.325581	129
EZE	0.325516	2132
CLT	0.325	80
UIO	0.323684	380
AMS	0.320755	53
MDE	0.318211	1565
GIG	0.314286	210
BOG	0.312855	1937
CTG	0.312684	339
BRC	0.309278	97
PTY	0.301575	1333
GRU	0.29924	1447
AEP	0.29682	283
NQN	0.293103	116
IGR	0.292453	106
BGA	0.289855	276
MEX	0.276995	213
CDG	0.27451	51
MVD	0.270833	240
CCS	0.268966	290
SSA	0.267606	71
TUC	0.234043	94
CWB	0.229008	131

Tabla 6 Proporción de demora por aeropuerto de origen, ordenada por proporción descendente.

Aeropuerto Destino	Proporción de demora	Observaciones
BSB	0.365385	104
ROS	0.363014	146
NQN	0.362637	91
SCL	0.361702	188
TUC	0.343137	102
BRC	0.342105	114
JFK	0.34139	331
UIO	0.337995	429

MDE	0.336879	1410
COR	0.336207	116
CTG	0.335211	355
LIM	0.330864	405
SJO	0.330827	133
CCS	0.329787	282
EZE	0.325137	2196
PTY	0.323272	1259
BOG	0.321839	1827
IGR	0.318584	113
CLT	0.317647	85
ASU	0.316832	101
GRU	0.316347	1511
PEI	0.312321	349
AEP	0.311828	279
CWB	0.311475	122
CLO	0.308869	327
MEX	0.307317	205
BGA	0.304985	341
IAH	0.303797	79
BAQ	0.296407	334
MIA	0.283747	363
AMS	0.280702	57
GUA	0.27972	143
SSA	0.278481	79
MVD	0.273063	271
GIG	0.269608	204
MDZ	0.268519	108
MAD	0.260355	169
FLN	0.237705	122
POA	0.232323	99
CDG	0.156863	51

Tabla 7 Proporción de demora por aeropuerto de origen, ordenada por proporción descendente.

Ruta aérea (única)	Proporción de demora	Observaciones
BOG-JFK	0.454545	121
GRU-MIA	0.434426	122
BOG-EZE	0.432836	134
BOG-MAD	0.394231	104
EZE-GRU	0.386905	168
BSB-GRU	0.373206	209
EZE-SCL	0.371041	221
CCS-EZE	0.365854	123
BOG-LIM	0.362245	196
BAQ-MDE	0.358156	282
EZE-PTY	0.357143	126
IAH-PTY	0.351852	162
MDE-MIA	0.350649	154
BOG-CTG	0.345411	414
EZE-ROS	0.344371	302
GRU-MDE	0.344262	61
EZE-UIO	0.343949	157
BGA-MDE	0.343949	314
MDE-UIO	0.343478	230
GRU-JFK	0.342857	105
JFK-MDE	0.342282	149
MDE-PEI	0.341902	389
GRU-SCL	0.341615	161
ASU-EZE	0.338028	213
LIM-MDE	0.337017	181
PTY-SJO	0.334646	254
BOG-CLO	0.334365	323
COR-EZE	0.330612	245
EZE-LIM	0.329032	155
BOG-MIA	0.328244	131
BRC-EZE	0.327014	211
EZE-MDZ	0.325581	215
EZE-NQN	0.323671	207
BOG-UIO	0.321739	230
CLT-PTY	0.321212	165
LIM-PTY	0.320513	156
GRU-LIM	0.320312	128
MIA-PTY	0.319767	172
CLO-MDE	0.318937	301

PTY-UIO	0.317708	192
JFK-PTY	0.317568	148
MDE-PTY	0.317073	246
GRU-POA	0.311404	228
MEX-PTY	0.311377	167
GUA-PTY	0.309623	239
EZE-MAD	0.306931	101
EZE-IGR	0.305936	219
BOG-GRU	0.305344	131
AEP-EZE	0.30427	562
BOG-CCS	0.303644	247
AMS-GRU	0.3	110
GRU-MAD	0.299145	117
GIG-GRU	0.293436	259
CTG-MDE	0.292857	280
BOG-PEI	0.292683	328
EZE-TUC	0.290816	196
EZE-GIG	0.290323	155
BOG-MEX	0.288889	135
EZE-MVD	0.28739	341
BAQ-BOG	0.286445	391
BOG-MDE	0.286145	332
FLN-GRU	0.285141	249
EZE-JFK	0.284091	88
BOG-PTY	0.278689	244
EZE-MIA	0.278195	133
GRU-PTY	0.277311	119
GRU-SSA	0.273333	150
CWB-GRU	0.268775	253
GRU-MEX	0.267241	116
CCS-PTY	0.252475	202
BGA-BOG	0.250825	303
EZE-MDE	0.25	56
GRU-MVD	0.241176	170
CDG-GRU	0.215686	102

Tabla 8 Proporción de demora por ruta aérea única, ordenada por proporción descendente.